СБЕР УНИВЕРСИТЕТ

Основы NLP

Большие языковые модели и что за ними стоит

Боревский Андрей

План

1. Как представить слово в цифре?
2. Первые семантические эмбеддинги
3. Токены
4. Нейросети для работы с текстом
5. Как работают модели семейства GPT?
6. Адаптация больших языковых моделей
7. RAG подход
8. RLHF подход

СБЕР УНИВЕРСИТЕТ

Проблема №1

Как объяснить компьютеру, что такое слово?

Типы данных/как их видит компьютер

- **Таблицы –** числа передаем напрямую в нейросеть как признаки, а категории представляем порядковым номером или как новый признак

- **Картинки –** каждый пиксель изображения содержит в себе до трех чисел, определяющих его цвет, что и позволяет модели «видеть»

- **Звук –** записываемое аудио представляется в виде картинки, где слева направо фиксируются все волны по времени их записи и чем выше тональность, тем выше волна будет записана на изображении

- А как быть со **словами и текстом ?**

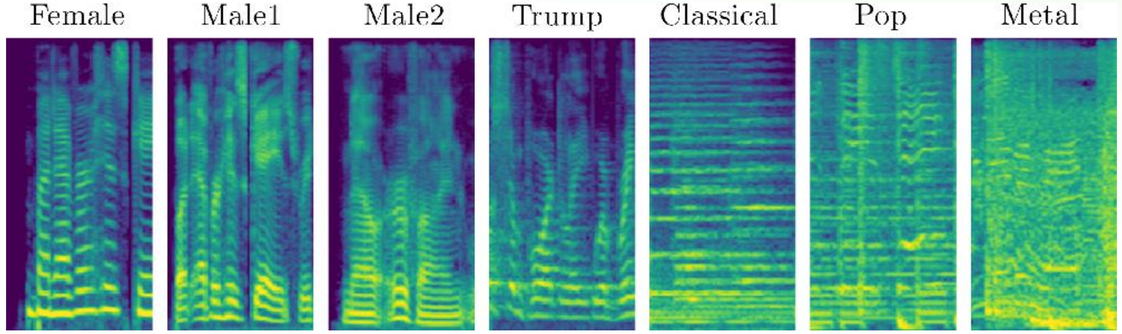

Текст/как его представить компьютеру?

«Мой дорогой, добрый мой друг – это очень дорогой подарок»

Текст/мешок слов

«Мой дорогой, добрый мой друг – это очень дорогой подарок»

	Мой	**Дорогой**	**Добрый**	**Друг**	**Это**	**Очень**	**Подарок**	**Спасибо**	**Пес**
Первый текст	2	2	1	1	1	1	1	0	0

Текст/мешок слов

«Мой дорогой, добрый мой друг – это очень дорогой подарок»

«Это мой пес, очень дорогой мой друг»

«Добрый друг – дорогой подарок»

	Мой	**Дорогой**	**Добрый**	**Друг**	**Это**	**Очень**	**Подарок**	**Спасибо**	**Пес**
Первый текст	2	2	1	1	1	1	1	0	0
Второй текст	2	1	0	1	1	1	0	0	1
Третий текст	0	1	1	1	0	0	1	0	0

Слово/как его представить в числах?

Пес = [___, ___, ___, ___, ___, …]

Слово/как его представить в числах?

Слово ближе к неживому или к человеку?

Насколько слово устаревшее?

Пес = [____, ____, ____, ____, ____, …]

Используется ли это в ремонте?

Является ли оно обзывательством?

Насколько слово положительное?

Слово/как его представить в числах?

Слово ближе к неживому или к человеку?

Насколько слово устаревшее?

Пес = [+77, +85, -64, -37, +10, …]

Насколько слово положительное?

Используется ли это в ремонте?

Является ли оно обзывательством?

Эмбеддинг – представление слова в виде чисел так, чтобы похожие слова имели схожие числа

Эмбеддинги/что это?

- У каждой точки на карте Земли есть свои **координаты**: своя долгота и широта!

  Москва: (55° широты, 37° долготы)

  Чебоксары: (56° широты, 47° долготы)

  Владивосток: : (43° широты, 131° долготы)

- Представим, что у нас есть две характеристики для каждого слова – **Положительность** и **Устарелость**.

- Создадим для всех слов карту по этим двум координатам вместо долготы и широты.

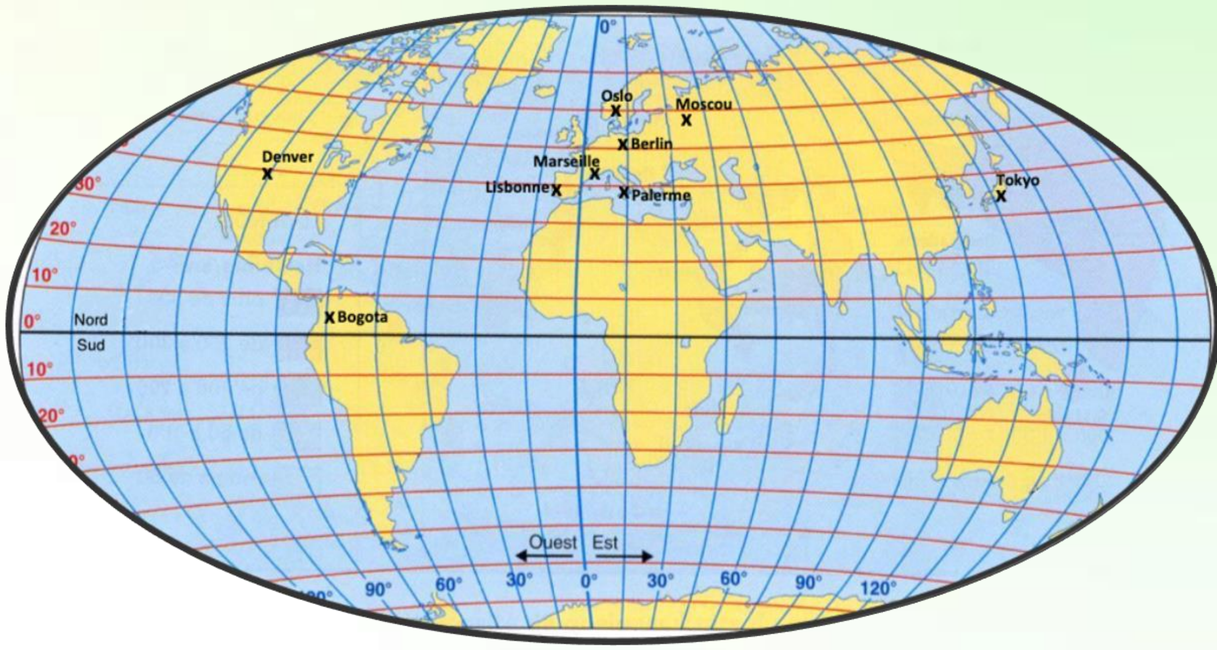

Эмбеддинги/что это?

Северо-восток займут «**Положительные современные слова**»:
вдохновение, успех, радость, семья

Север достанется «**Современным нейтральным словам**»:
астрофизика, нанотехнологии, нейросеть

Северо-запад отдадим «**Современным негативным словам**»

Если пойдем южней по нашей карте, будем встречать все более древние слова

Слова на нашей карте расположены осмыслено:
Чем они ближе, тем более схожи у них выбранные 2 характеристики

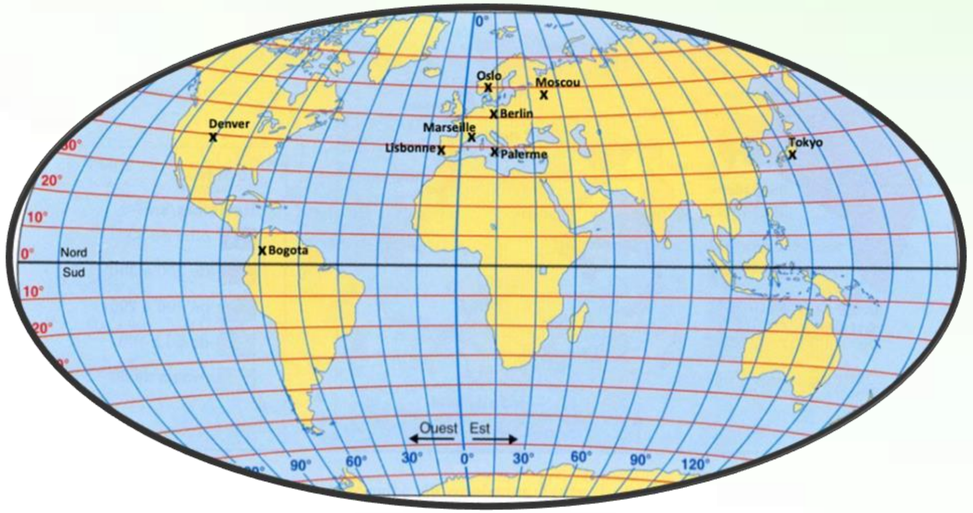

Эмбеддинги/сохранение семантики в числах

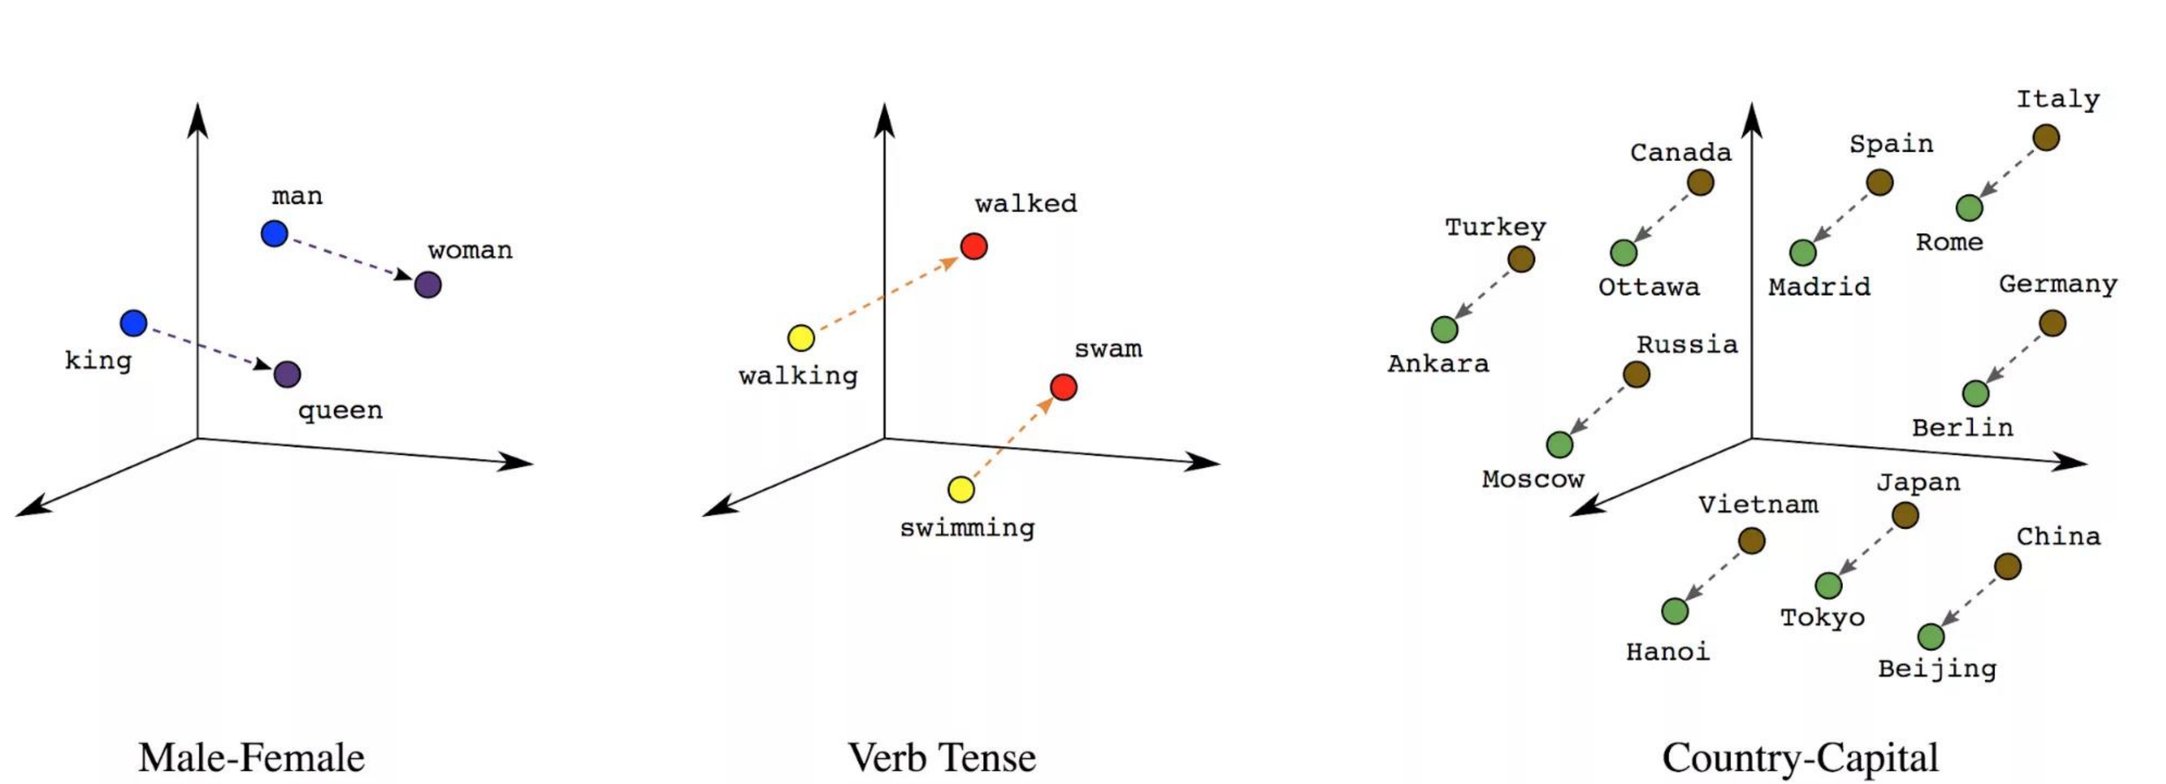

Male-Female

Verb Tense

Country-Capital

СБЕР УНИВЕРСИТЕТ

Проблема №2

Как создавать осмысленные представления слов?

Эмбеддинги/как их получить?

Слова	Я	гуляю	с	собакой	по	парку
Эмбеддинги	[...]	[...]	[...]	[...]	[...]	[...]

Эмбеддинги/как их получить?

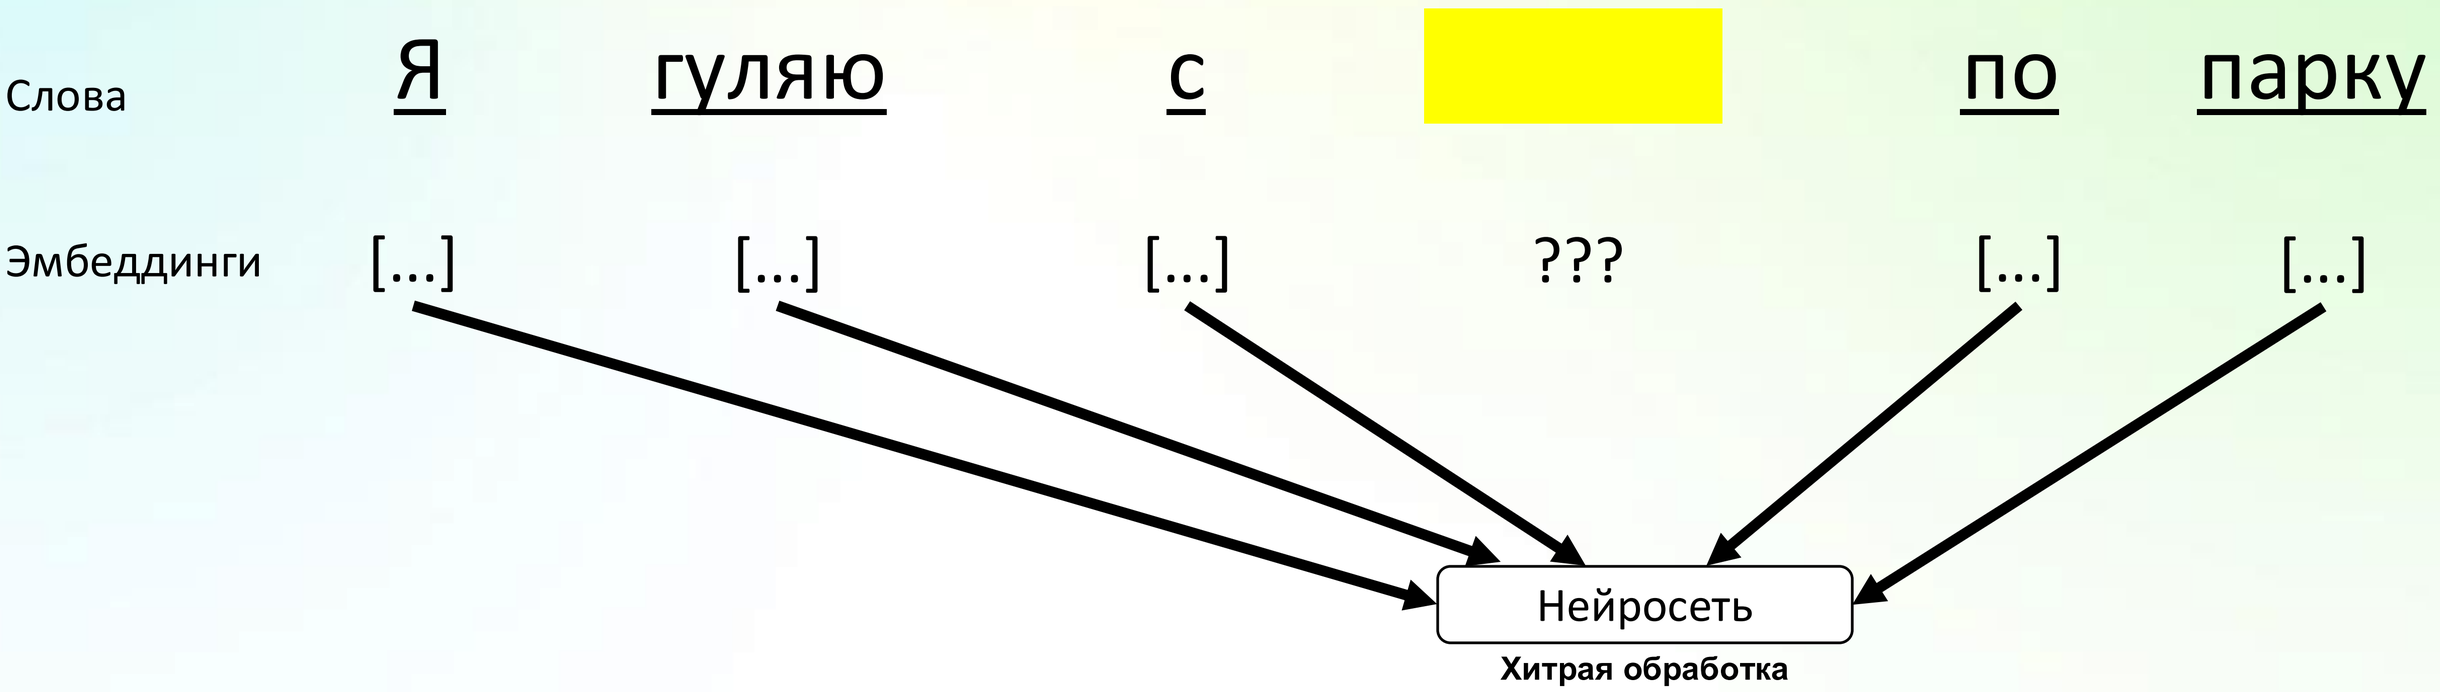

Эмбеддинги/как их получить?

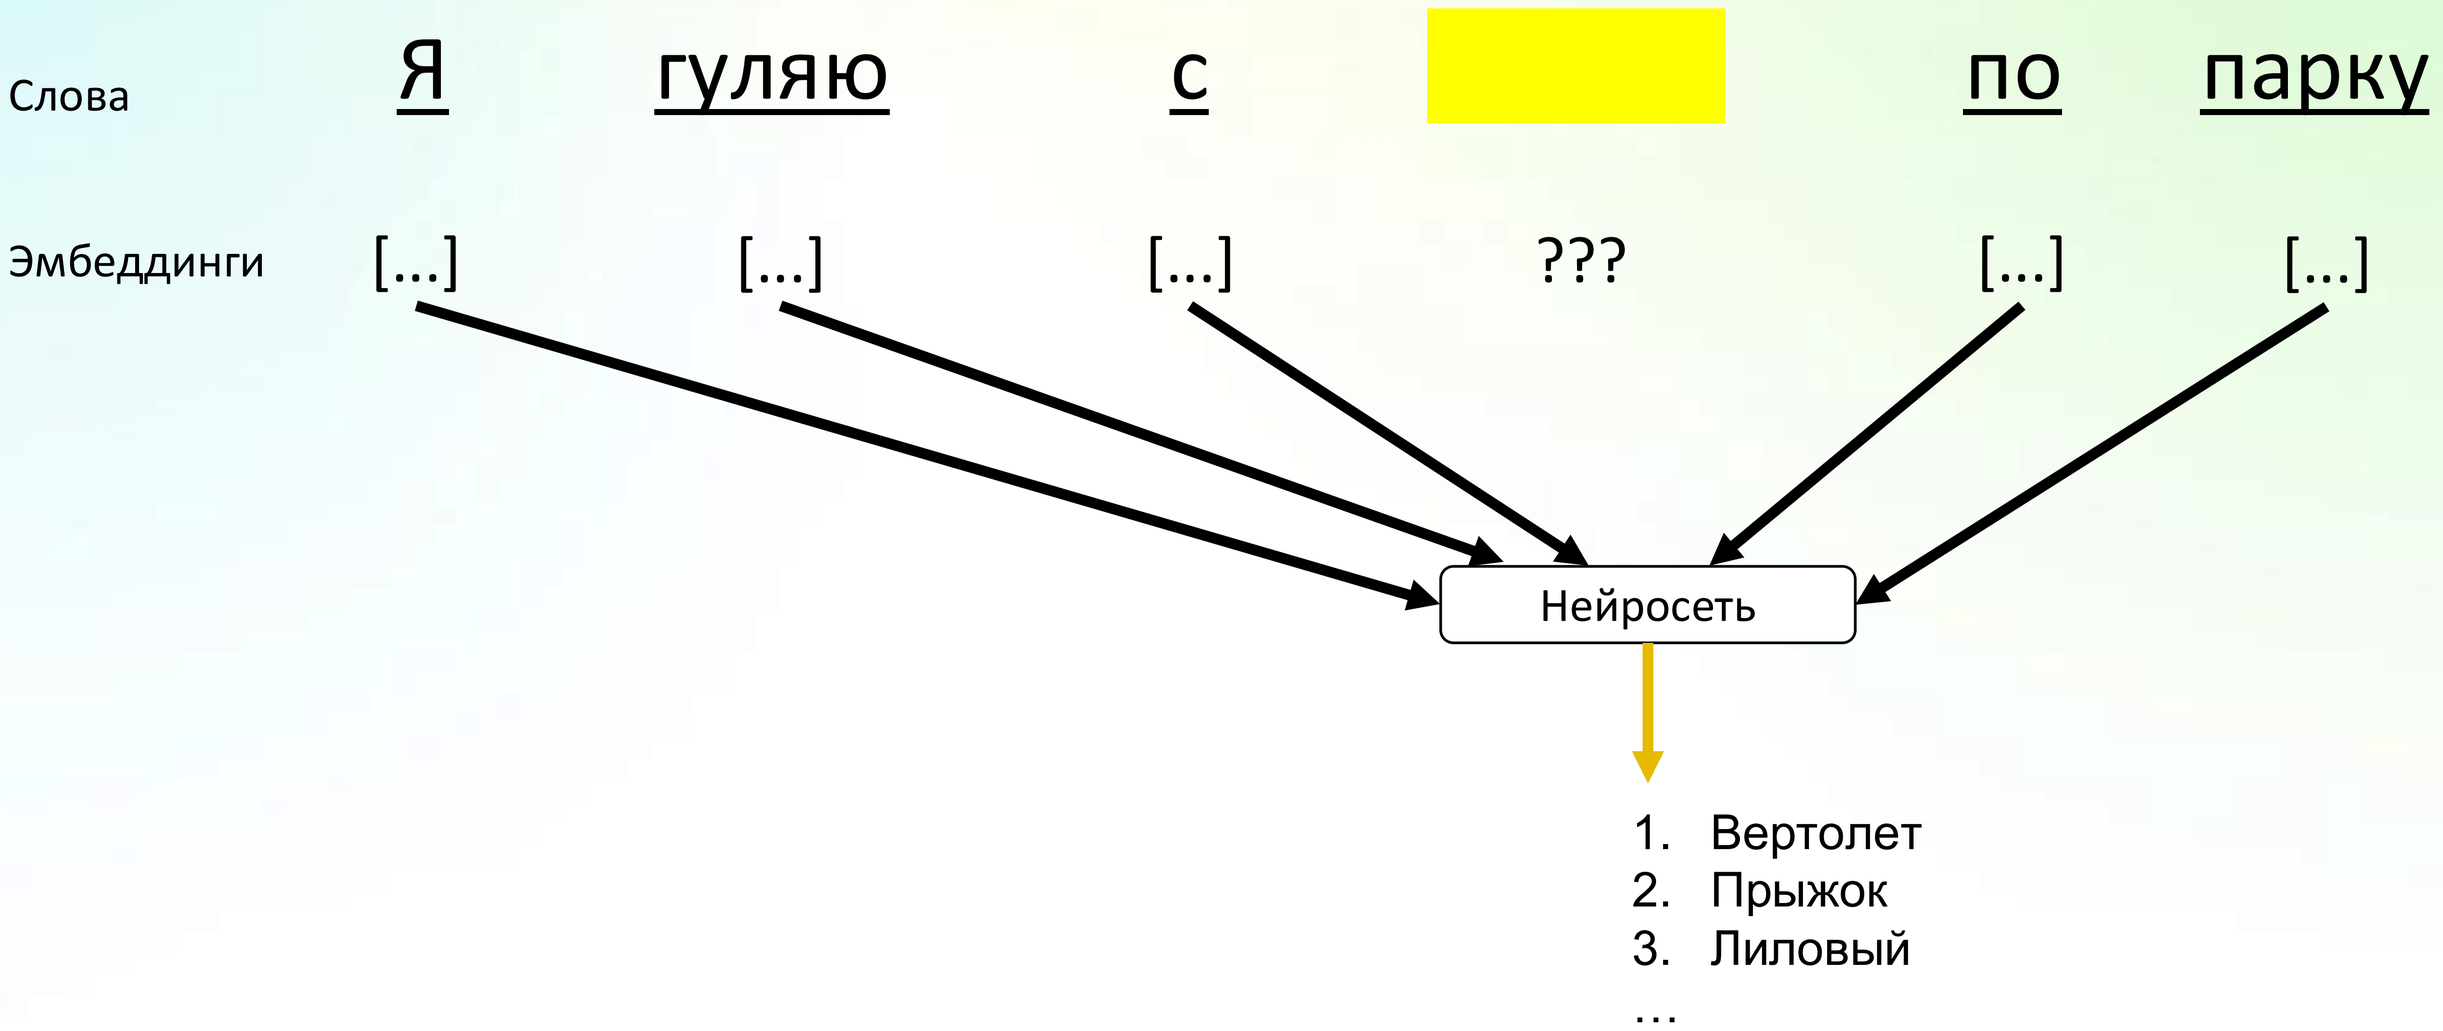

Эмбеддинги/как их получить?

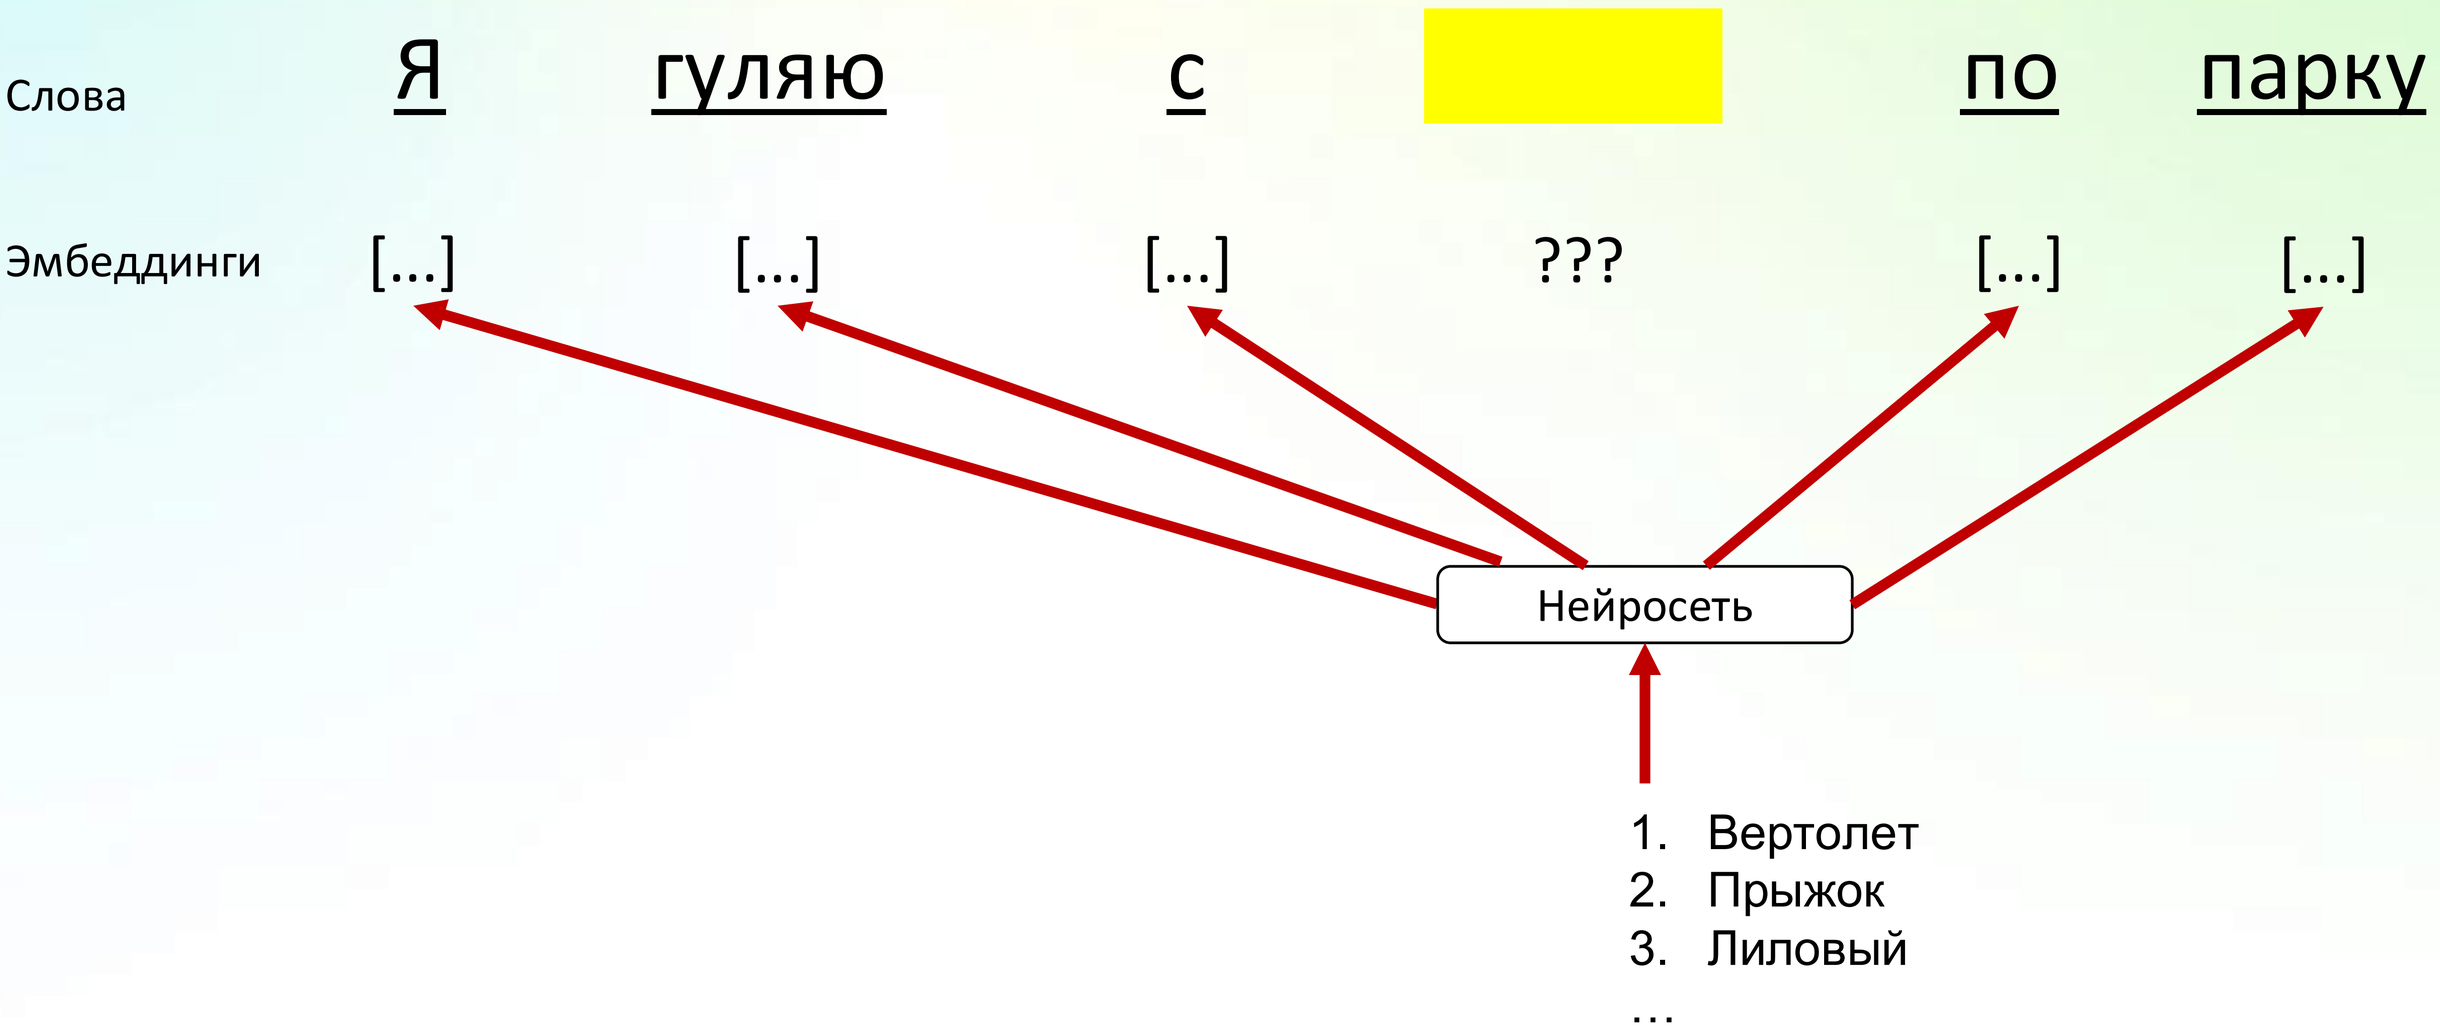

Эмбеддинги/как их получить?

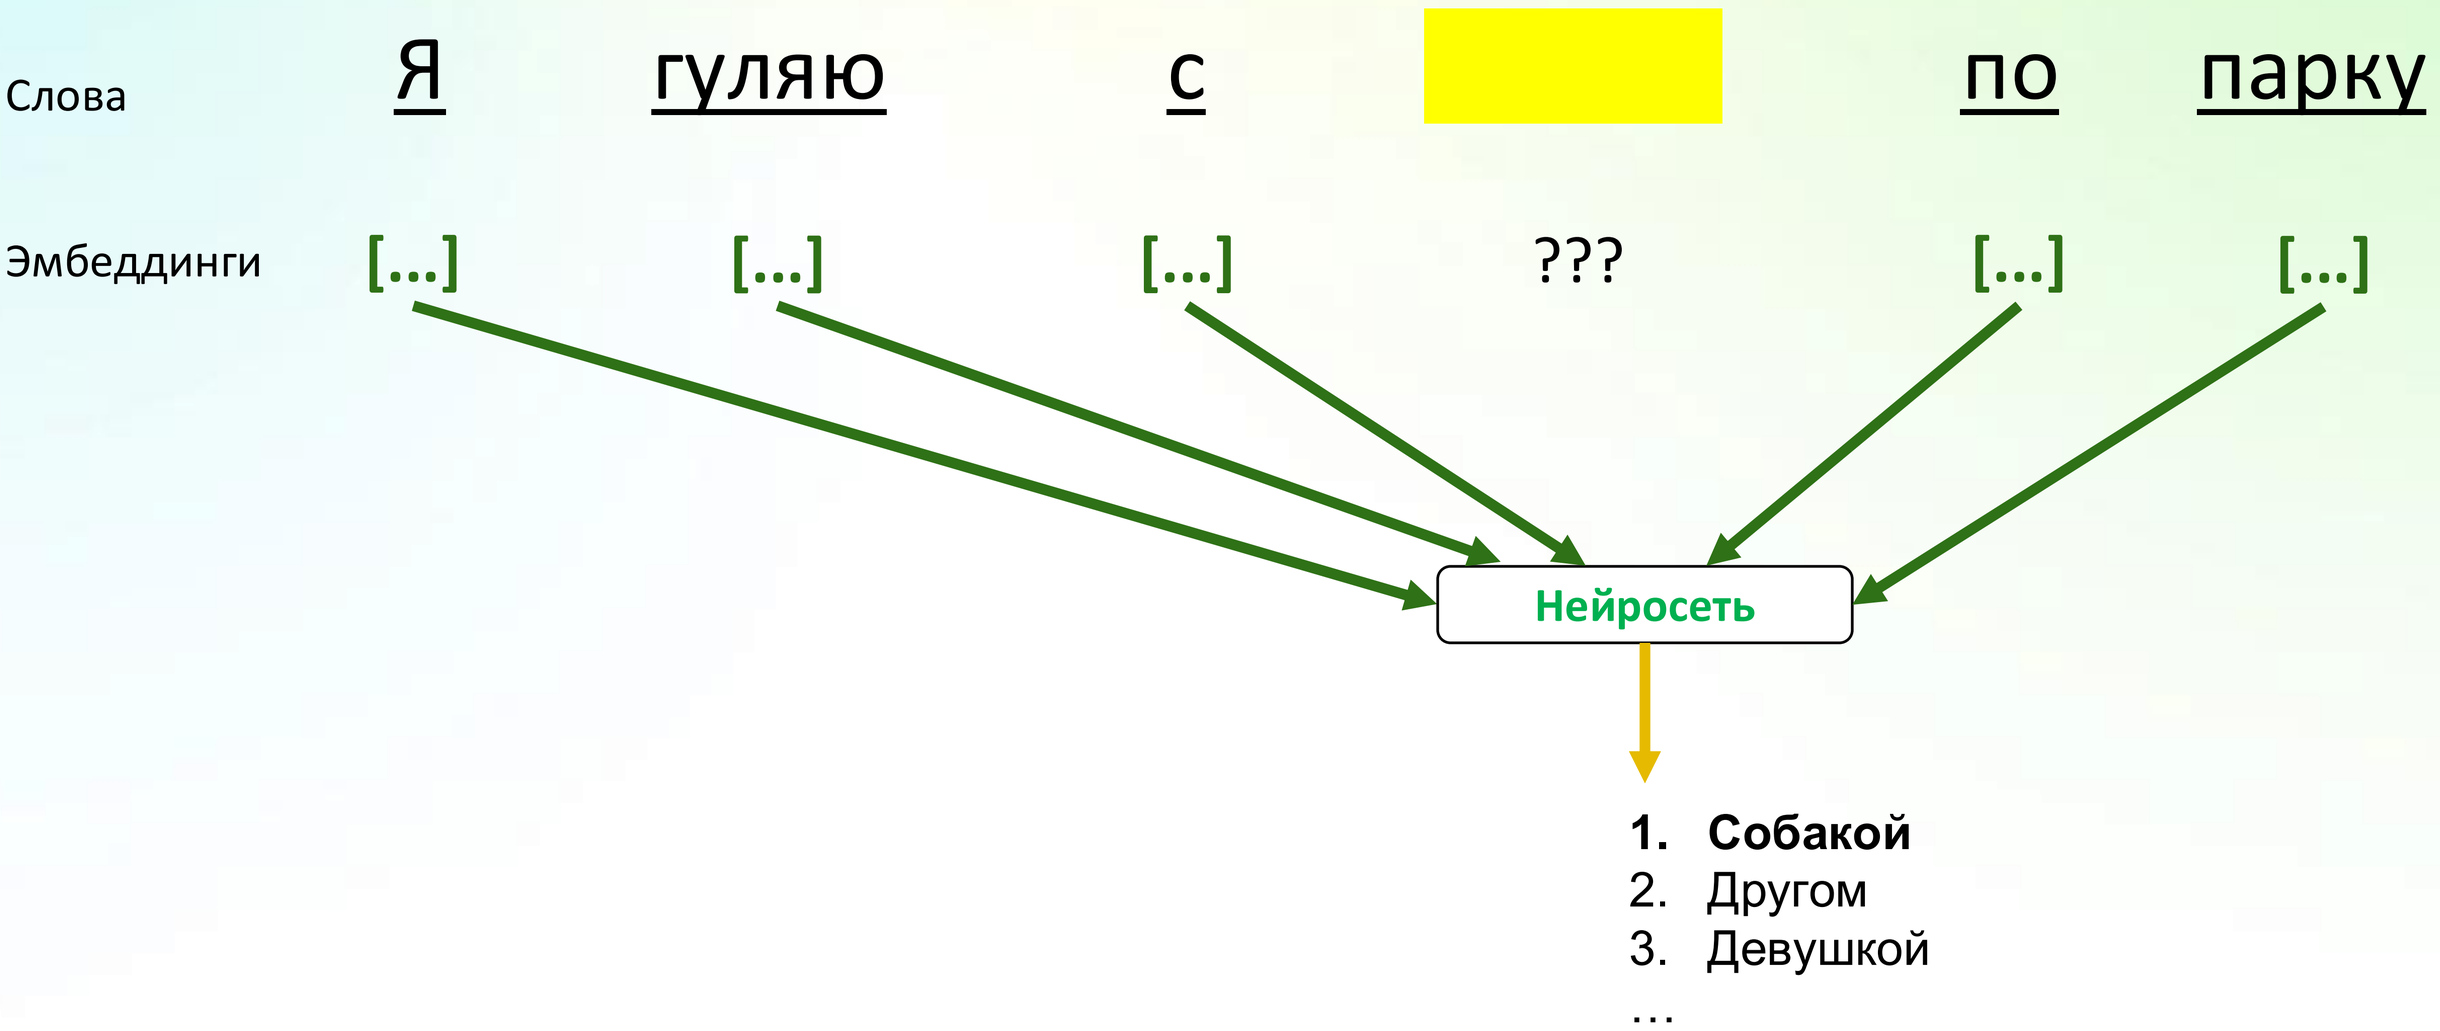

СБЕР УНИВЕРСИТЕТ

Проблема №3

А почему мы создаем эмбеддинги на слова?

LLM/как передать текст в модель?

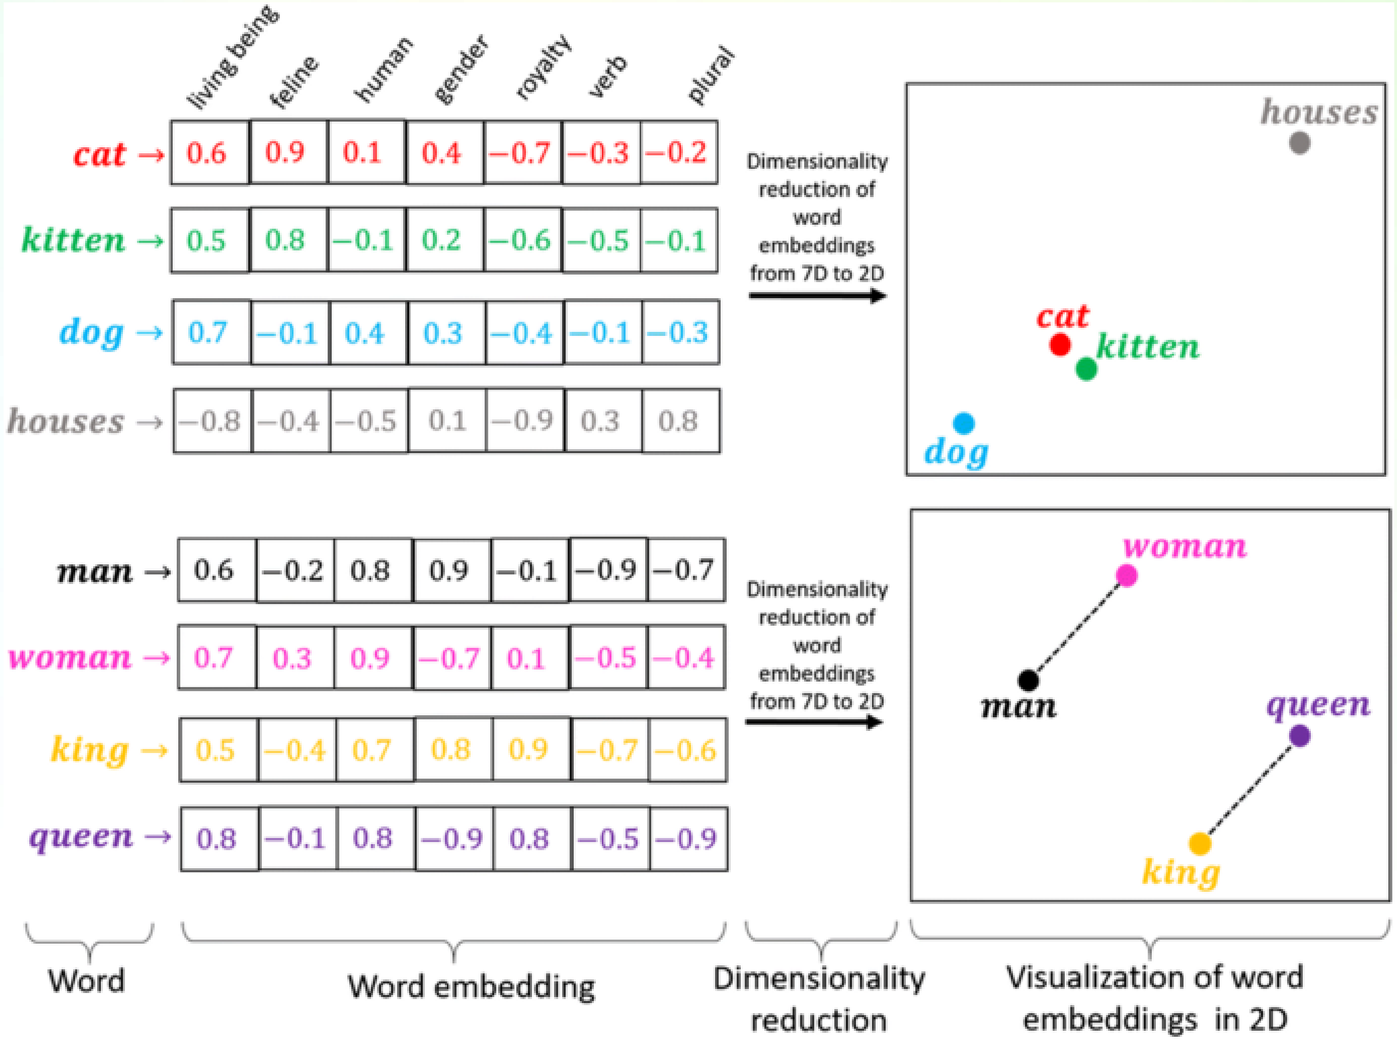

LLM/как передать текст в модель?

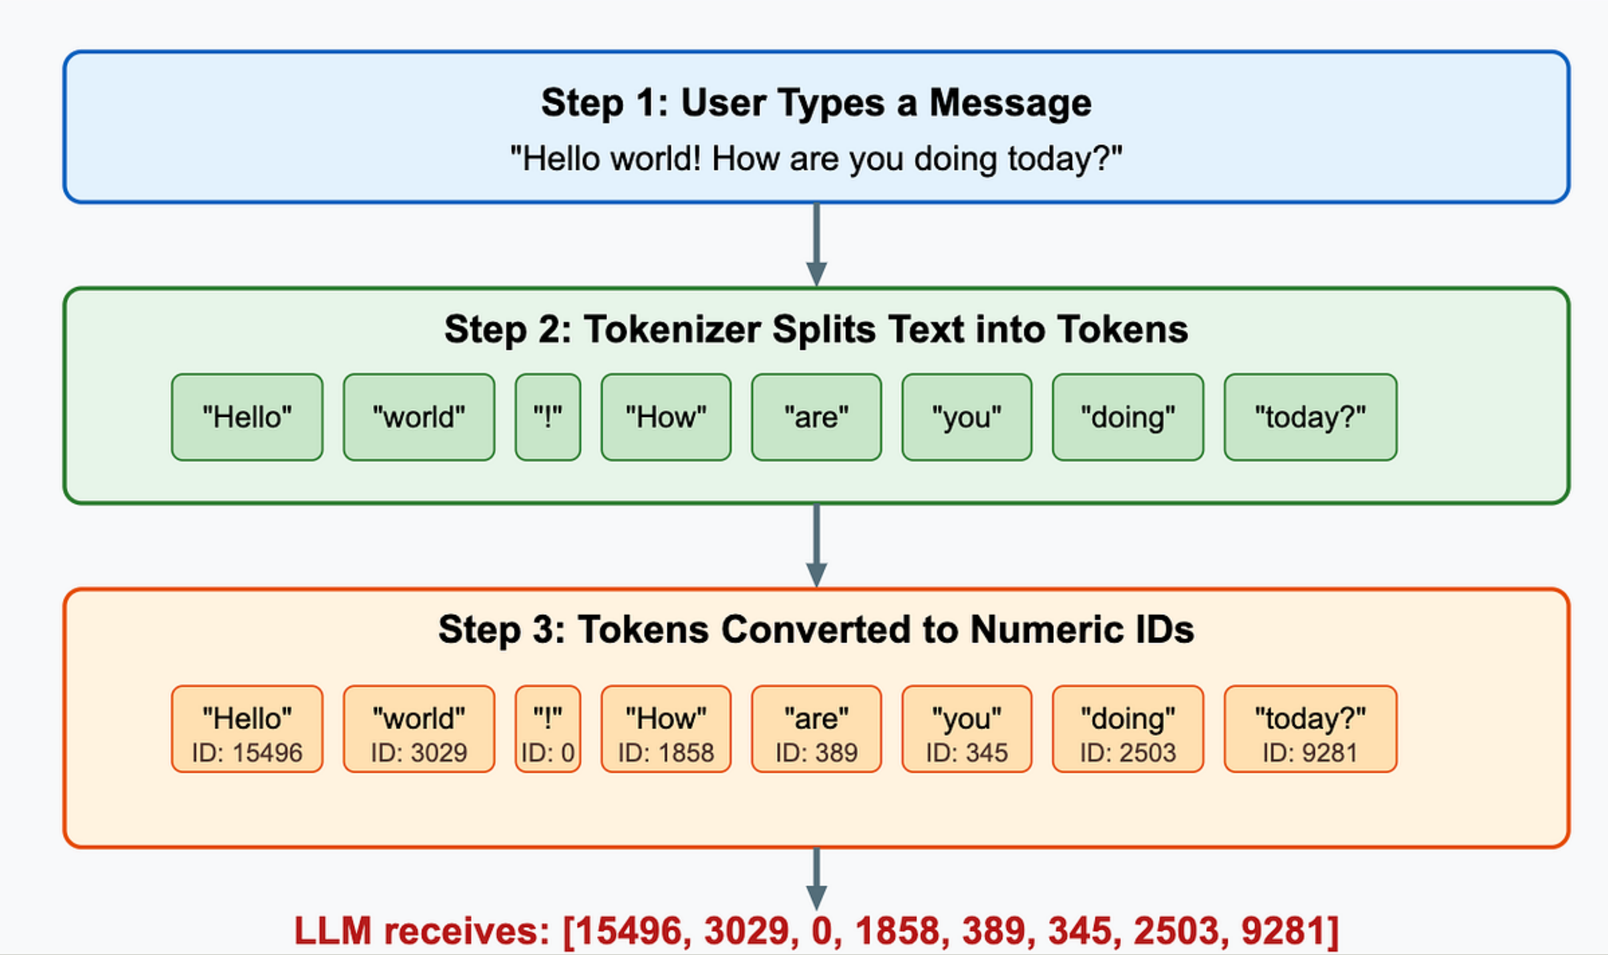

Токенизация/семейство подходов

Complete Words | Subwords | Prefixes | Characters | Special Tokens | Spaces | Emojis | Punctuation

Tokenizer Method	“unhappy”	“Hello world”	“🧠 🤖 ”	“learning123”	“pre-trained”
BPE Byte Pair Encoding	un happy 2 tokens	Hello _ world 3 tokens	🧠 🤖 2 tokens	learn ing 1 2 3 5 tokens	pre - train ed 4 tokens
WordPiece Google’s method	un ##happy 2 tokens	Hello world 2 tokens	🧠 🤖 2 tokens	learn ##ing ##1 ##2 ##3 5 tokens	pre ##- ##train ##ed 4 tokens
SentencePiece Language-agnostic	_ un happy 3 tokens	_Hello _world 2 tokens	_ 🧠 🤖 3 tokens	_ learn ing 1 2 3 6 tokens	_ pre - train ed 5 tokens
Unigram Probabilistic apprach	unhappy 1 token	_Hello _world 2 tokens	_ 🧠 🤖 3 tokens	_ learning 1 2 3 3 tokens	_ pre - trained 4 tokens

Токенизация/byte pair encoding

1. Инициализация
Словарь состоит из всех отдельных символов текста

2. Подсчет пар
Считаем, как часто встречается каждая пара соседних символов

3. Объединение
Объединяем самую частую пару в один новый токен

4. Повторение
Повторяем шаги 2-3 нужное количество раз

aaabdaaabac	
aaaabdaaabac	Replace Z = aa
ZabdZabac	Replace Y = ab
ZYdZYac	Replace X = ZY
XdXac	Final compressed string

LLM/как передать текст в модель?

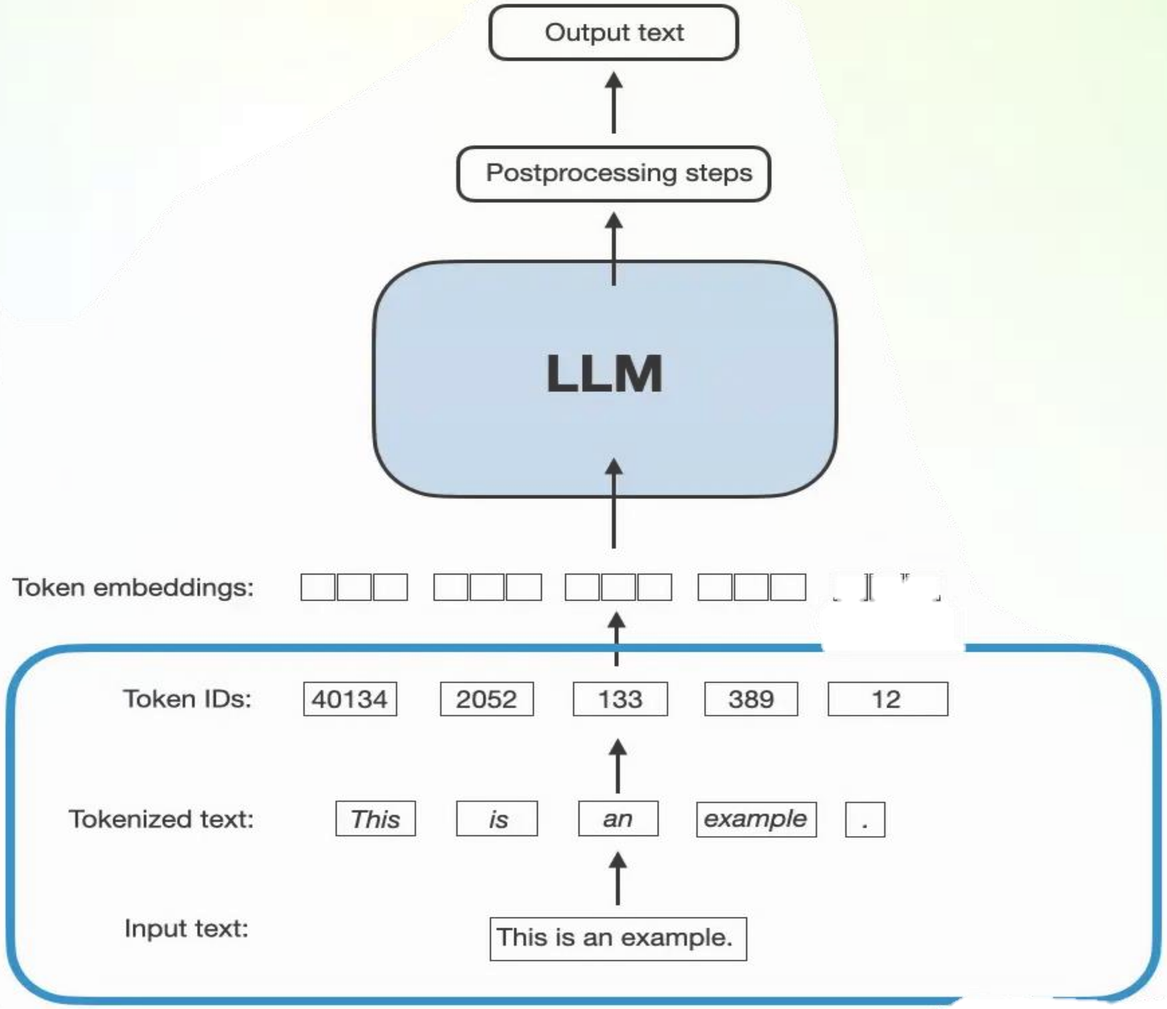

СБЕР УНИВЕРСИТЕТ

Проблема №4

Как работают и что предсказывают LLM?

Эмбеддинги/чего им не хватает?

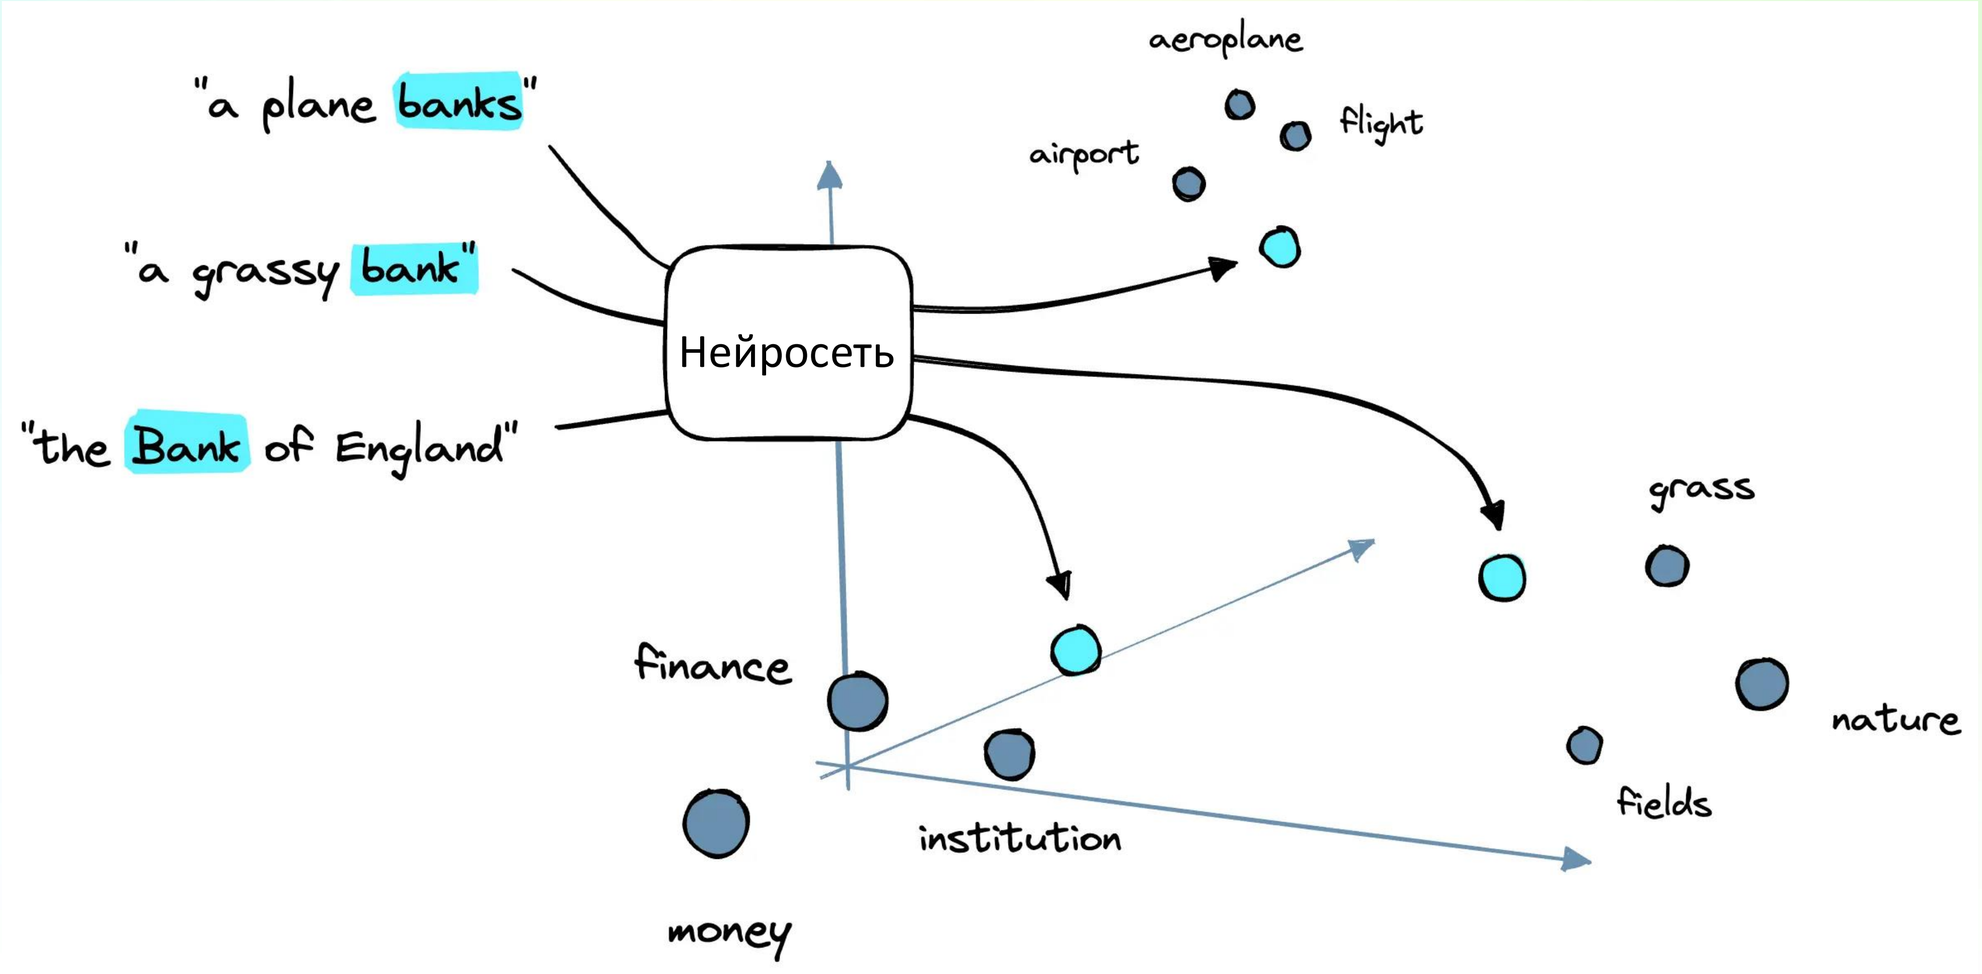

Большие Языковые модели/контекст в нейросетях

- Самые популярные генеративные языковые модели получают на вход именно эмбеддинги

- Один токен – один эмбеддинг. А что с омонимами и контестом в целом?

Нейросеть будет насыщать эмбеддинг каждого токена другими эмбеддингами из окружающего контекста

Вариант 1: угадывать слова внутри предложений по контексту
Вариант 2: угадывать следующее слово по предыдущим

Оба варианта строятся вокруг одной идеи **– слоя Attention**

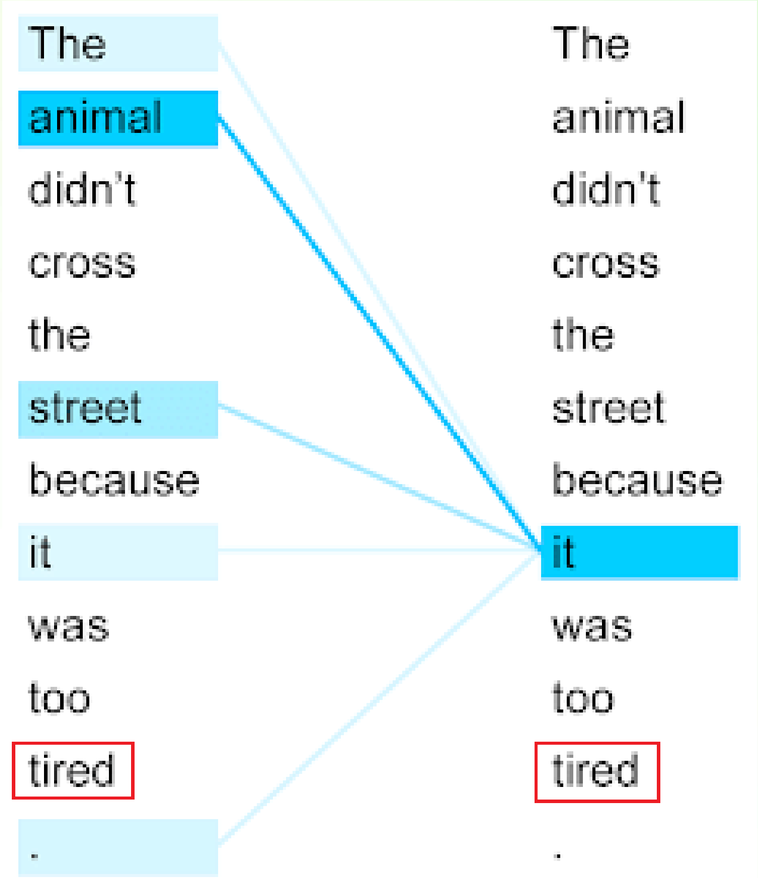

Большие Языковые модели/контекст в нейросетях

- У моделей семейства GPT одна задача из варианта 2:
  предсказать следующее слово по всем предыдущим

- Алгоритм обучения:
  1. Собираем все доступные тексты
  2. Токенизируем тексты (BPE)
  3. Строим случайные эмбеддинги
  4. Подаем в нейросеть текст, представленный последовательность эмбеддингов
  5. Эмбеддинги насыщаются контекстом друг друга
  6. На выходе нейросеть предсказывает следующее слово
  7. Обновляем все веса и эмбеддинги, пока качество не вырастет

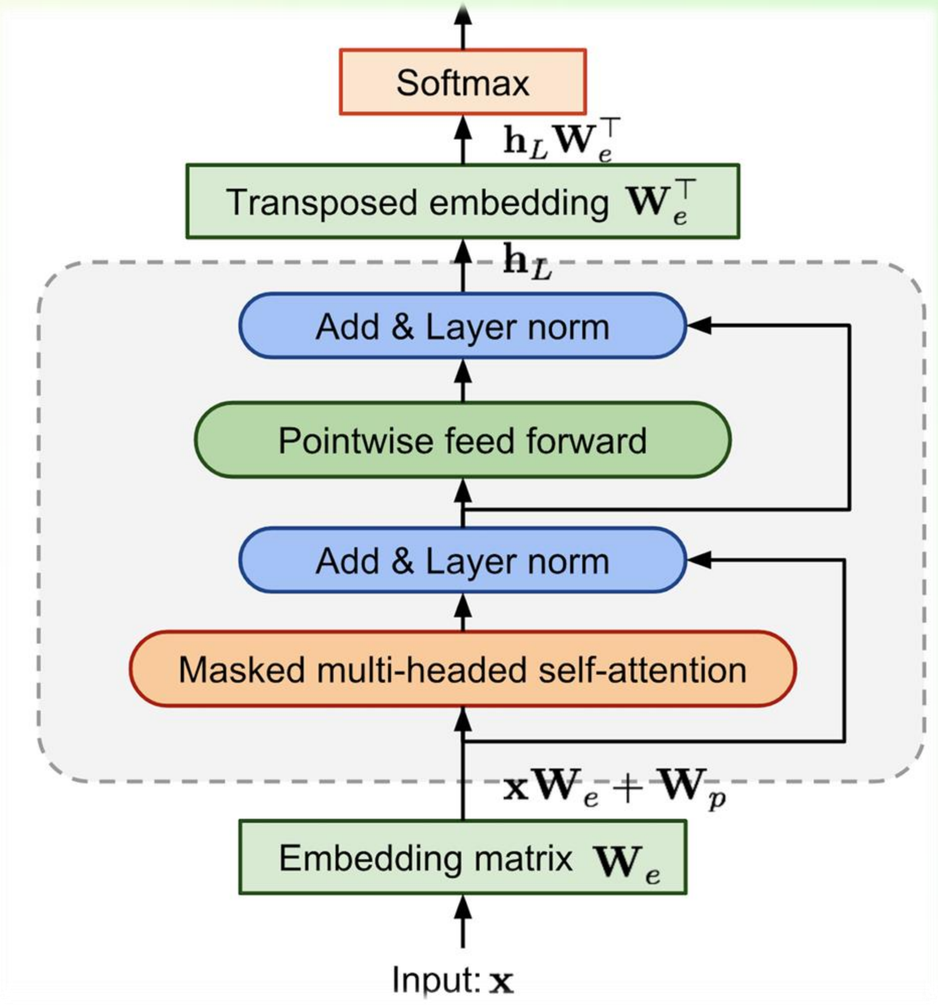

СБЕР УНИВЕРСИТЕТ

Проблема №5

Как адаптировать модели под свои задачи?

Большие Языковые модели/адаптация

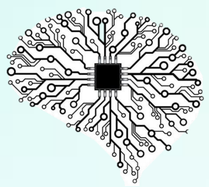

Собственная LLM

1. Безопасность данных
2. Развитие отечественных технологий
3. Высокая стоимость разработки
4. Многочисленность задач

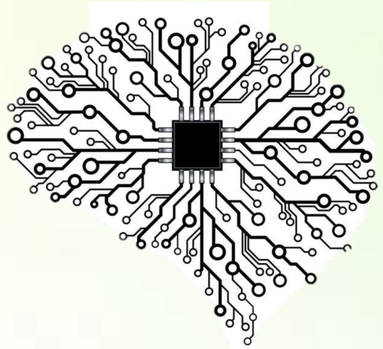

Внешняя LLM

Большие Языковые модели/адаптация

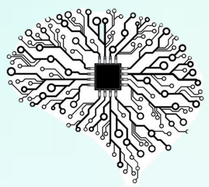

Собственная LLM

1. Безопасность данных
2. Развитие отечественных технологий
3. Высокая стоимость разработки
4. Многочисленность задач

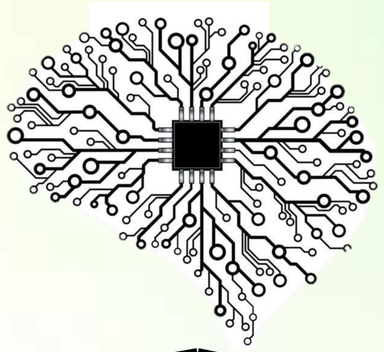

Внешняя LLM

Дообучение

RAG

RLHF

Большие Языковые модели/дообучение

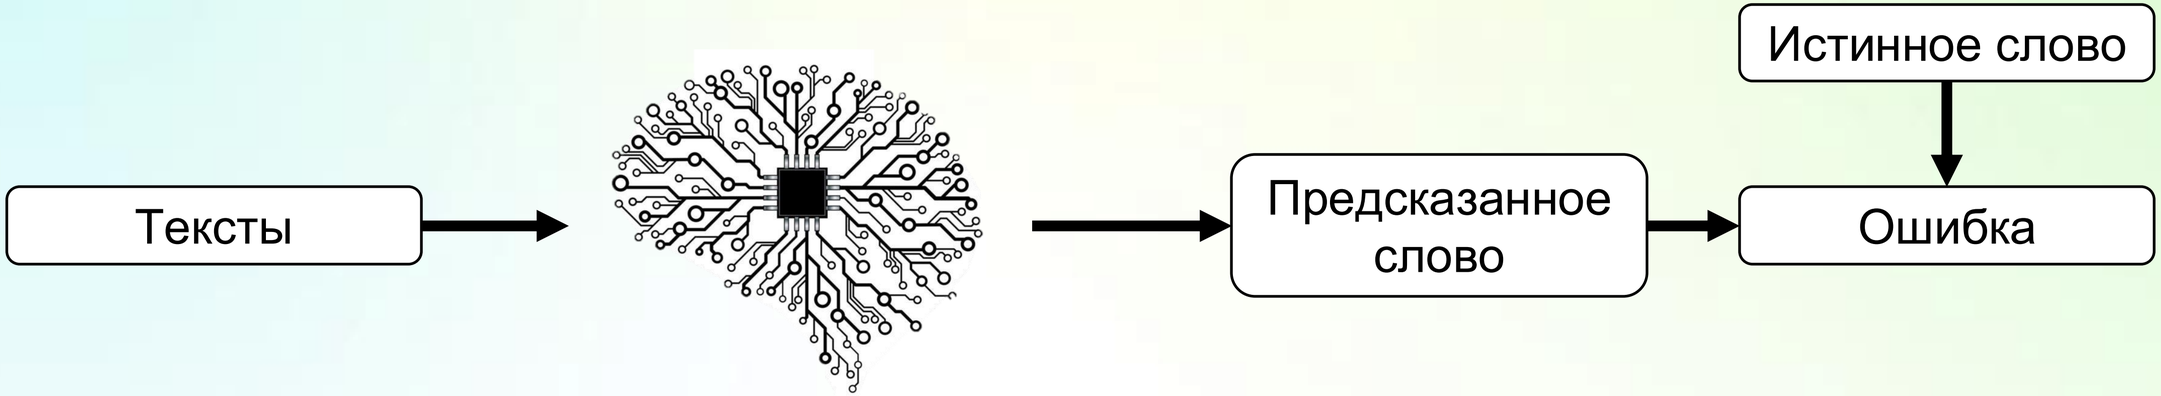

Большие Языковые модели/дообучение

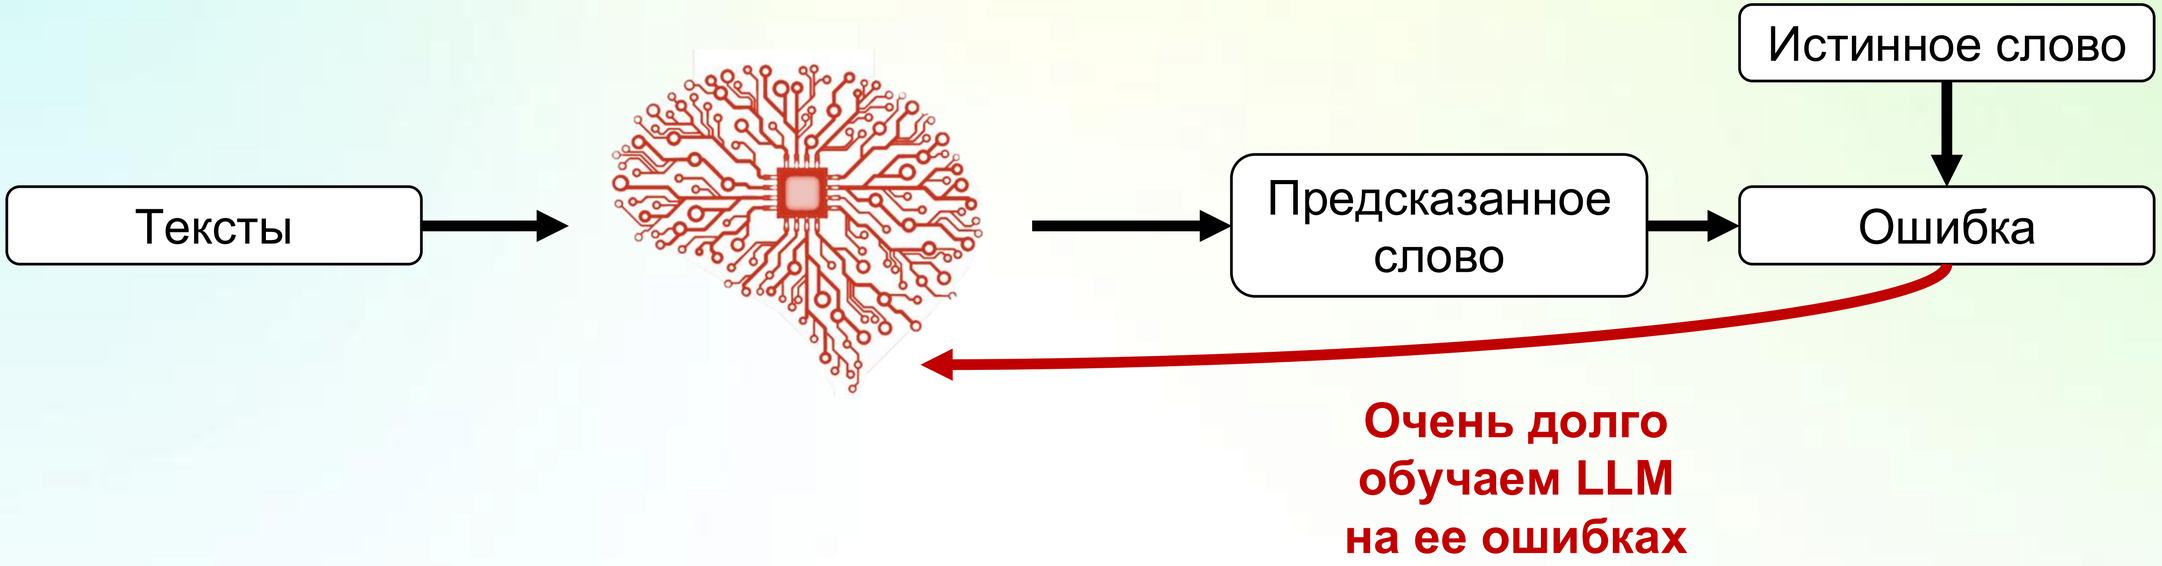

Большие Языковые модели/дообучение

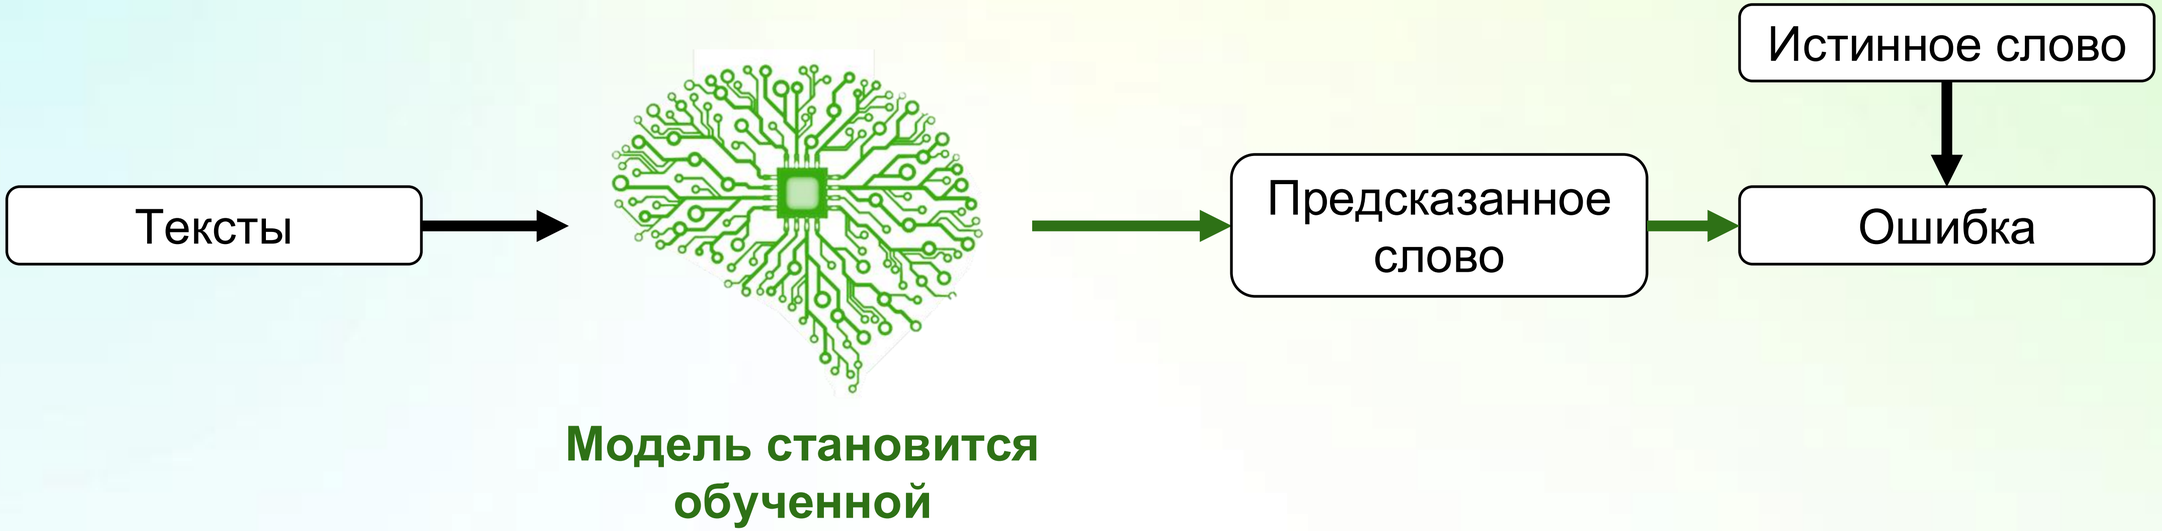

Большие Языковые модели/дообучение

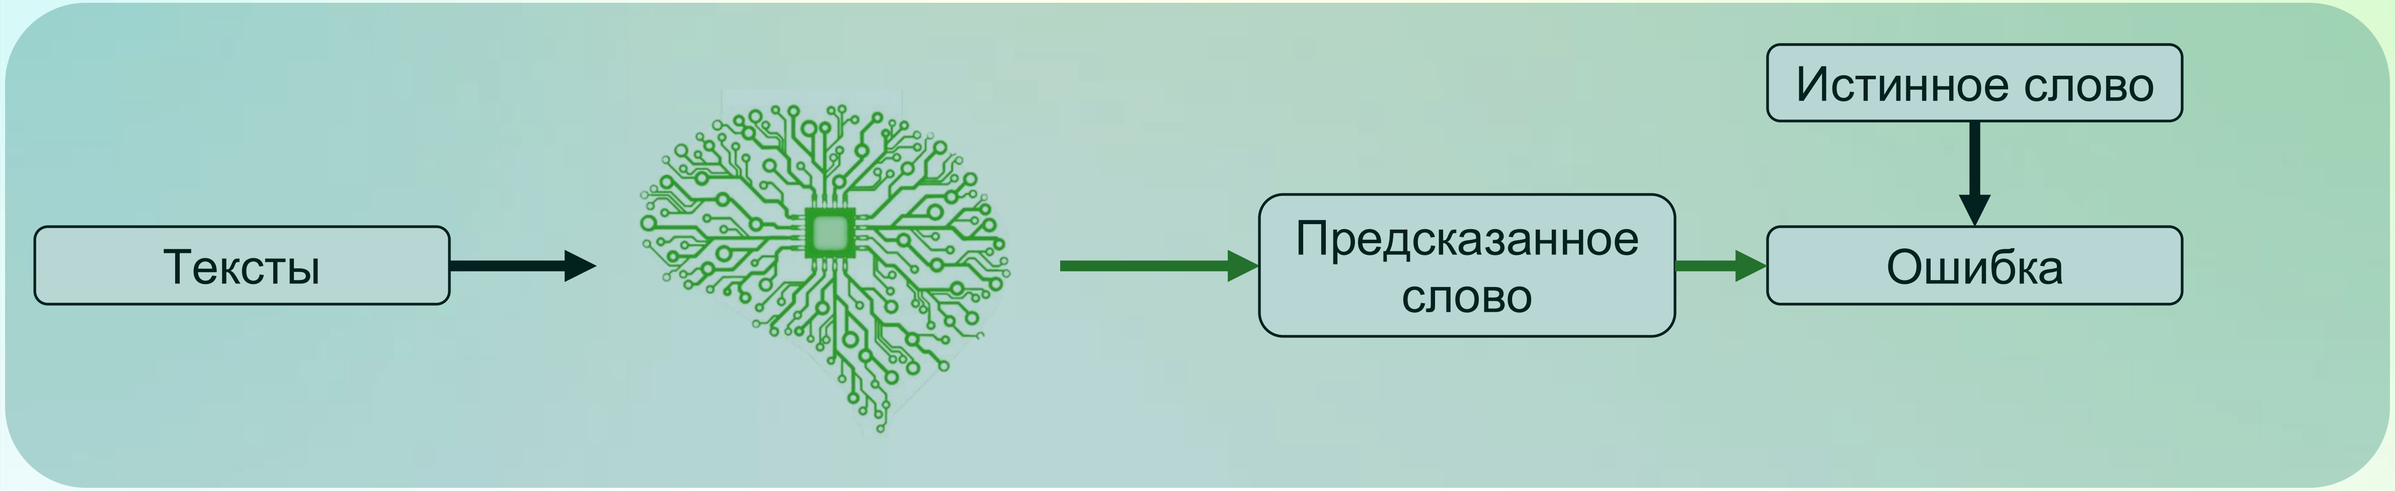

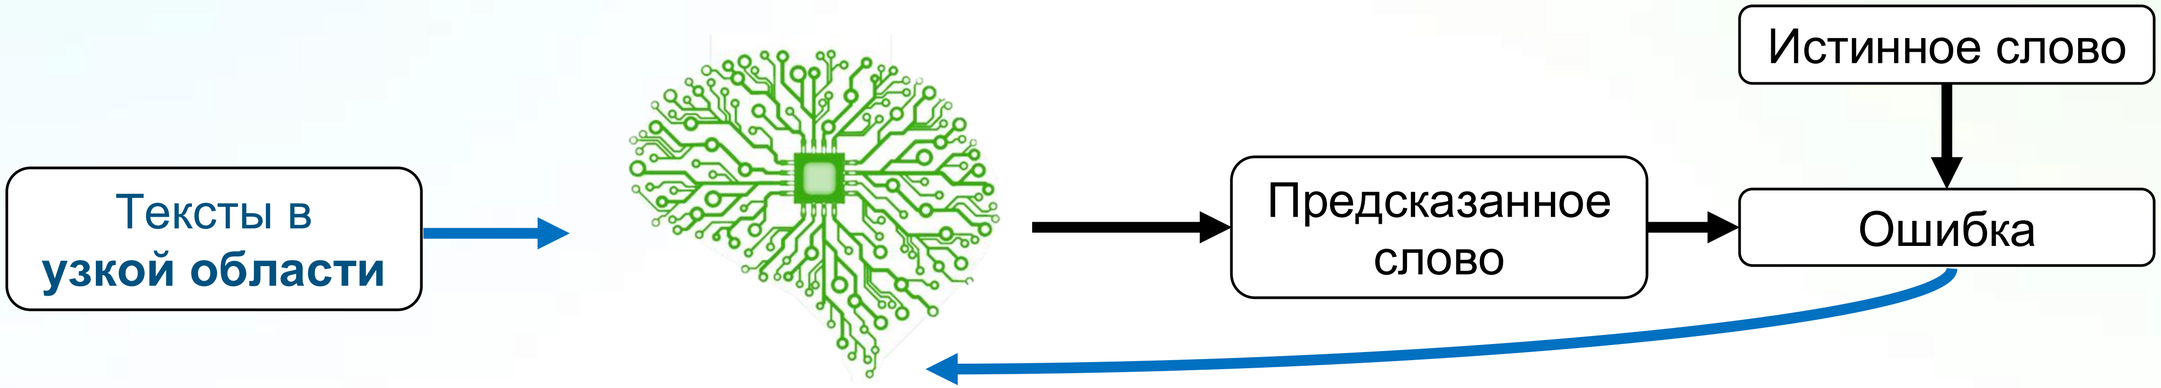

Повторяем процесс на меньшей выборке

Большие Языковые модели/эффективное дообучение

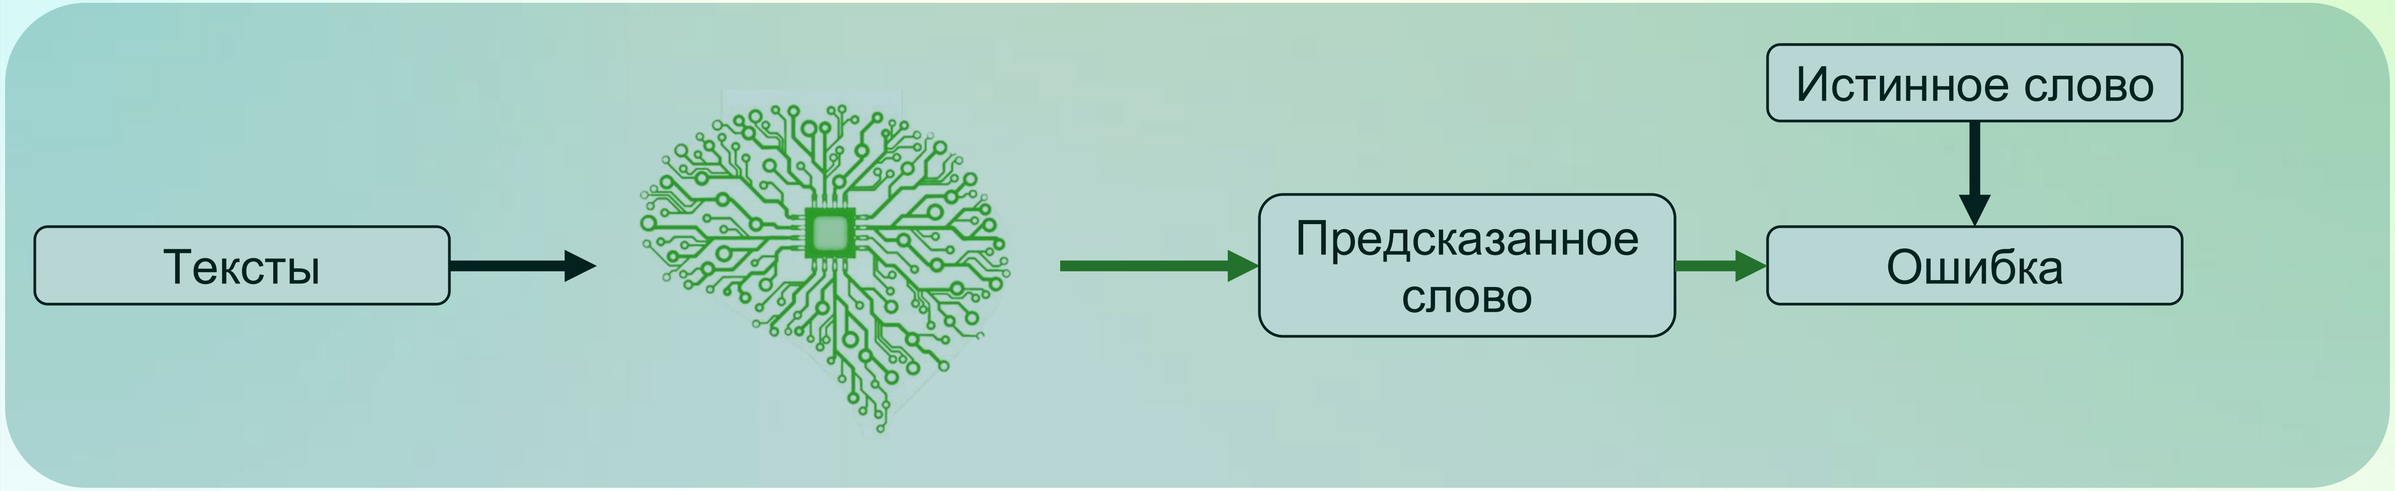

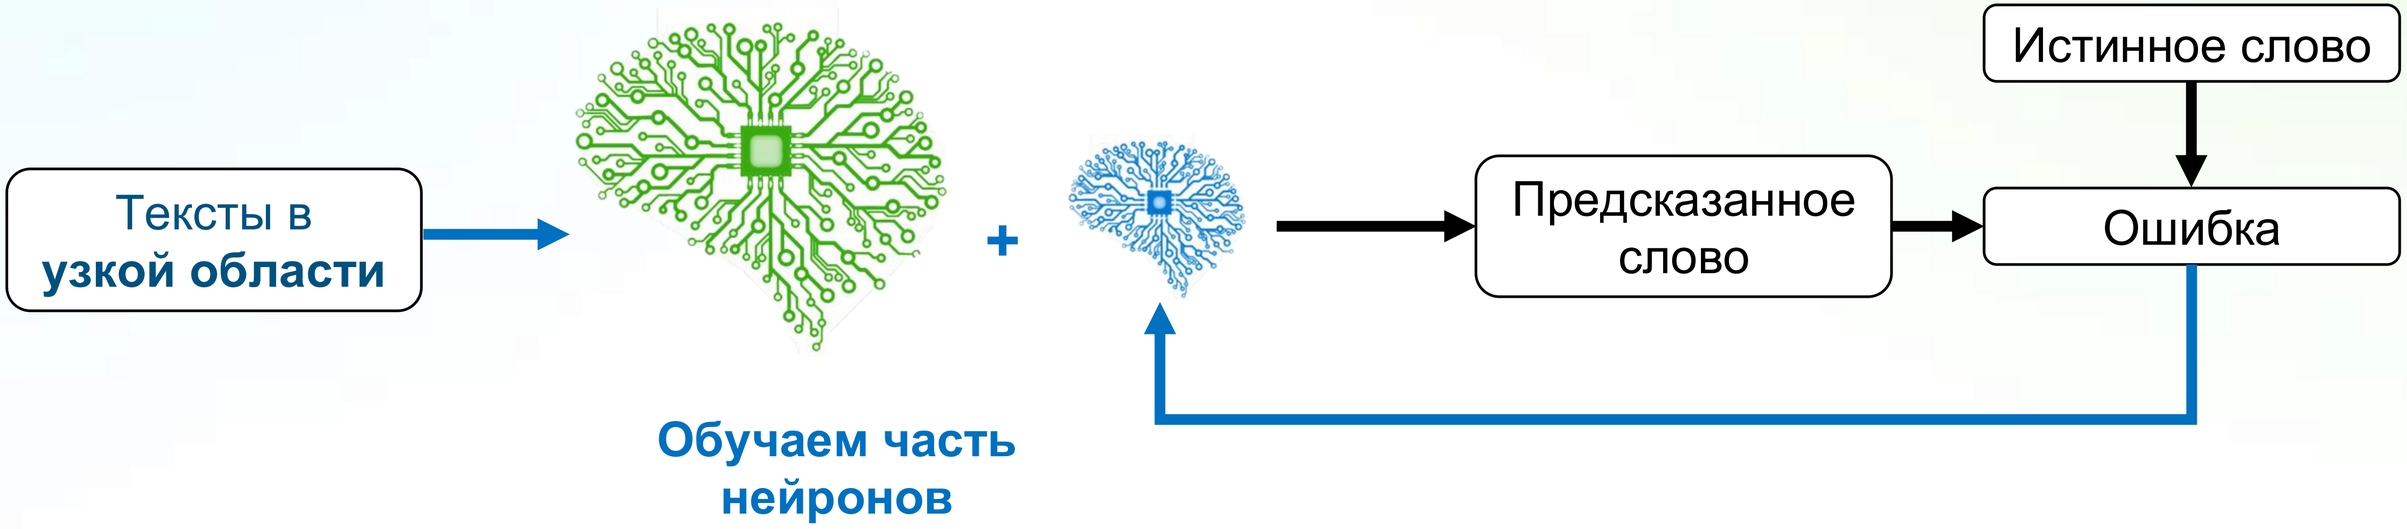

Большие Языковые модели/RAG

Запрос пользователя

Кто выиграл выборы в Америке в 2024 году?

Модель 2022 года

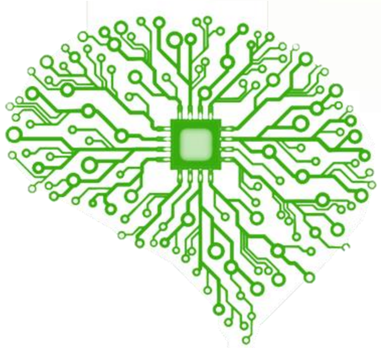

Документы

Большие Языковые модели/RAG

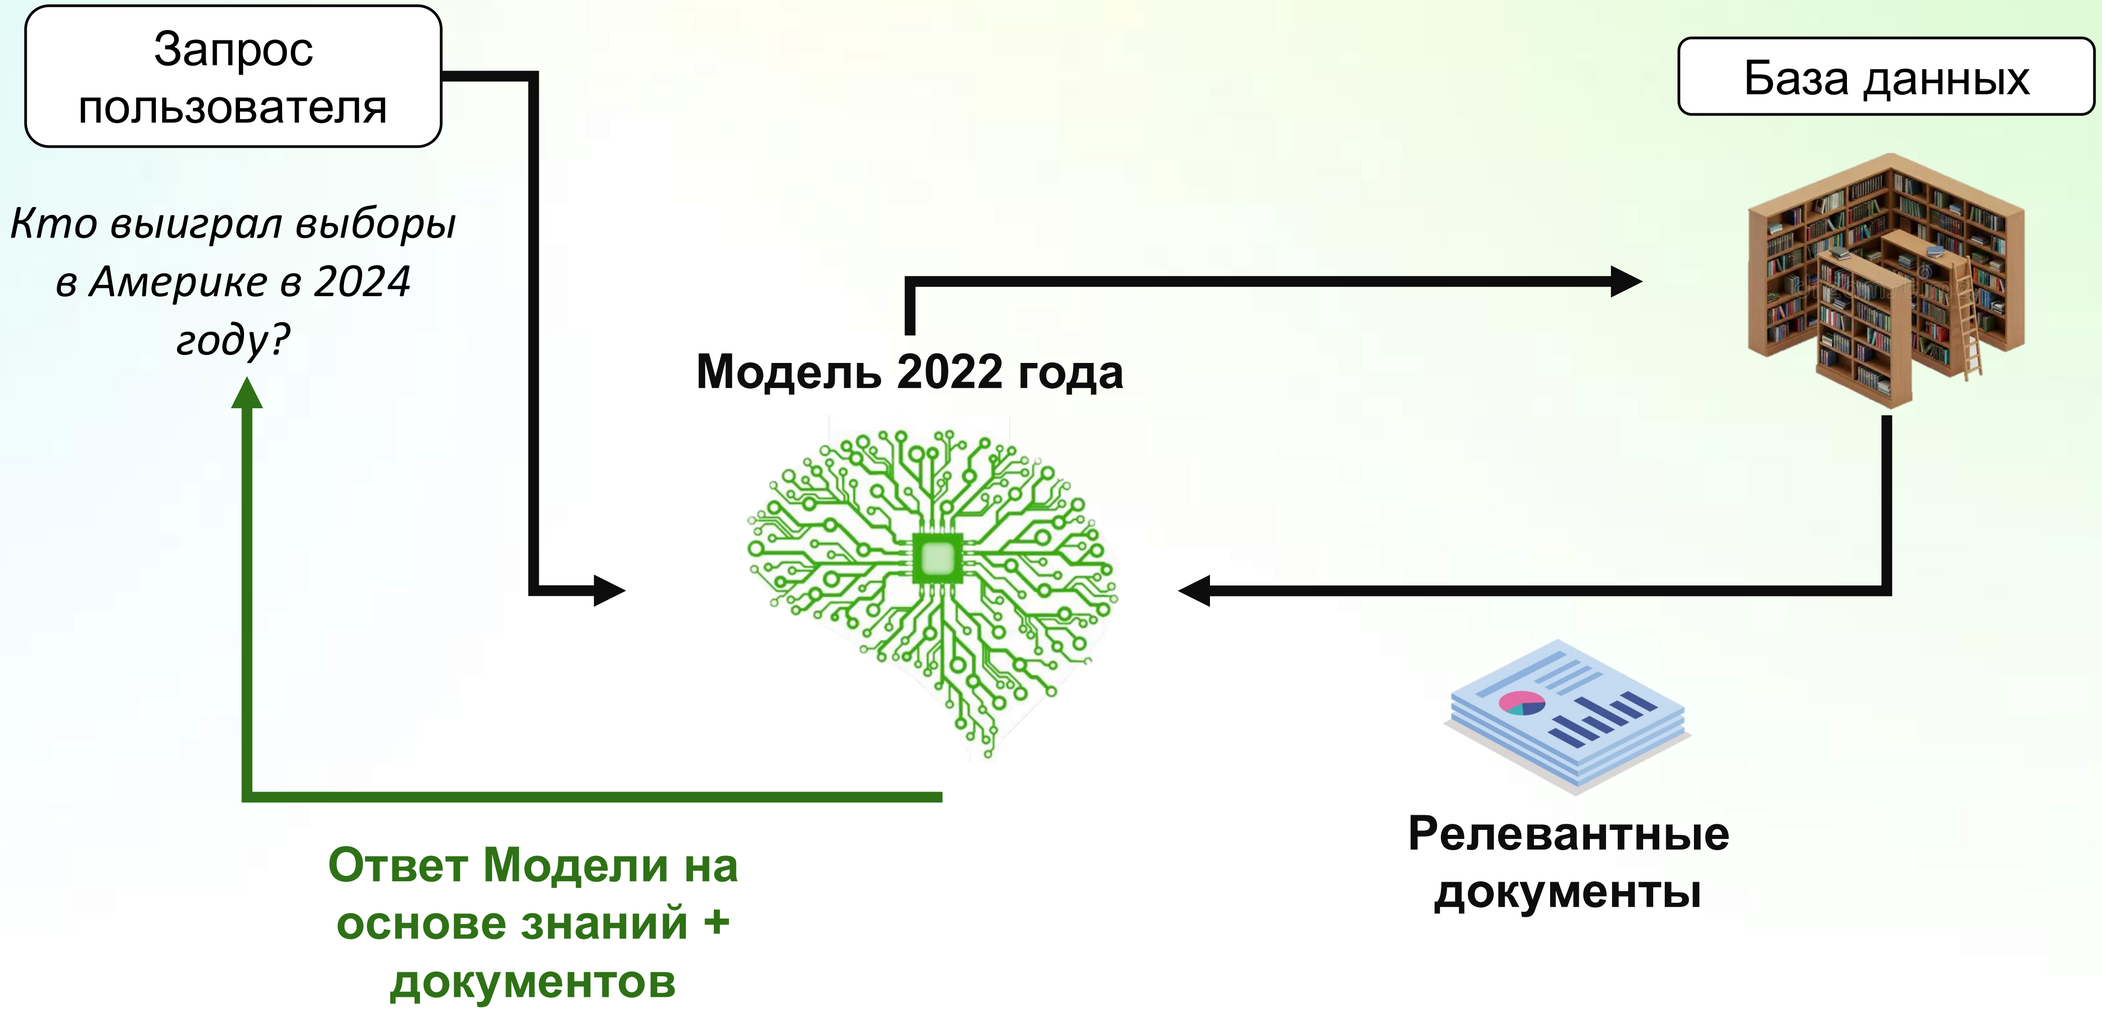

Большие Языковые модели/RLHF

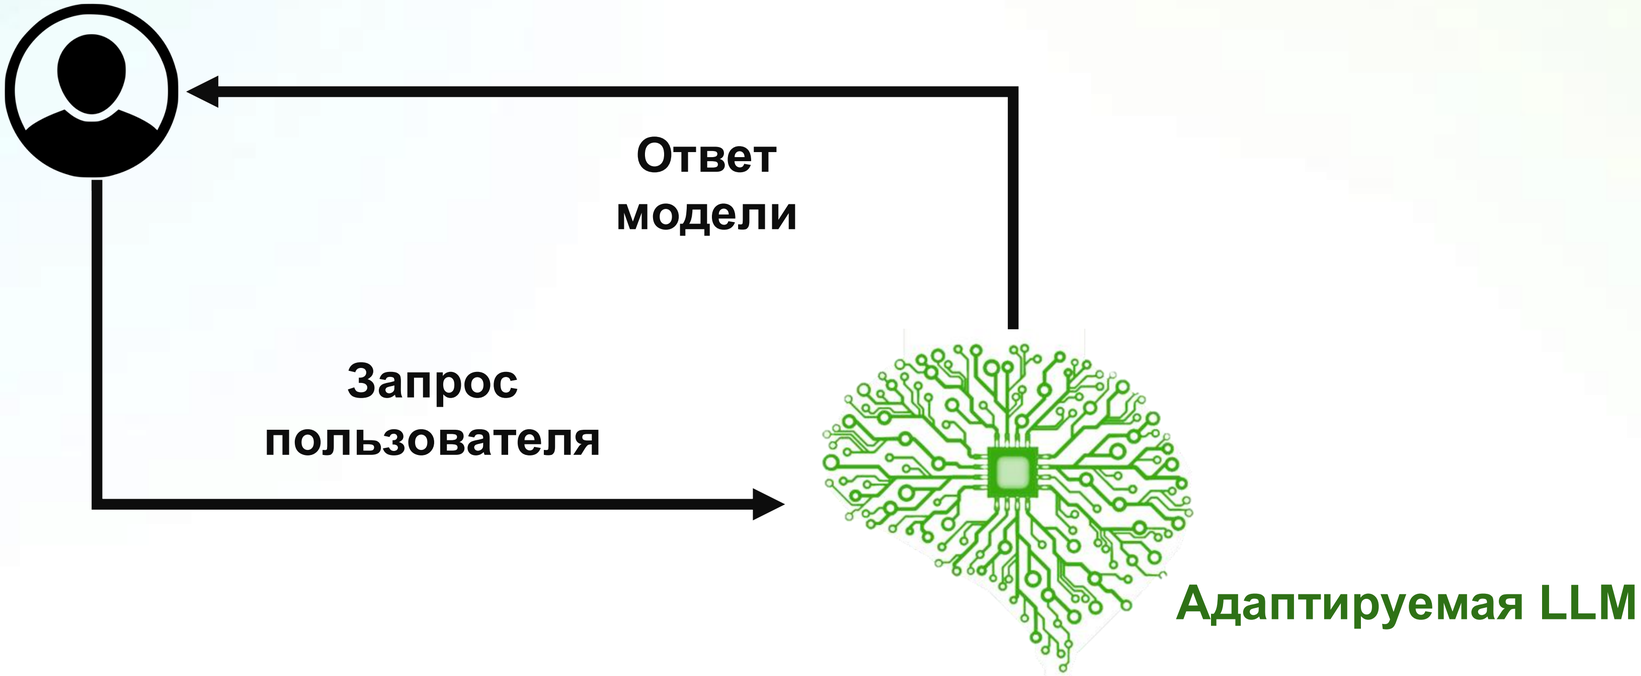

Большие Языковые модели/RLHF

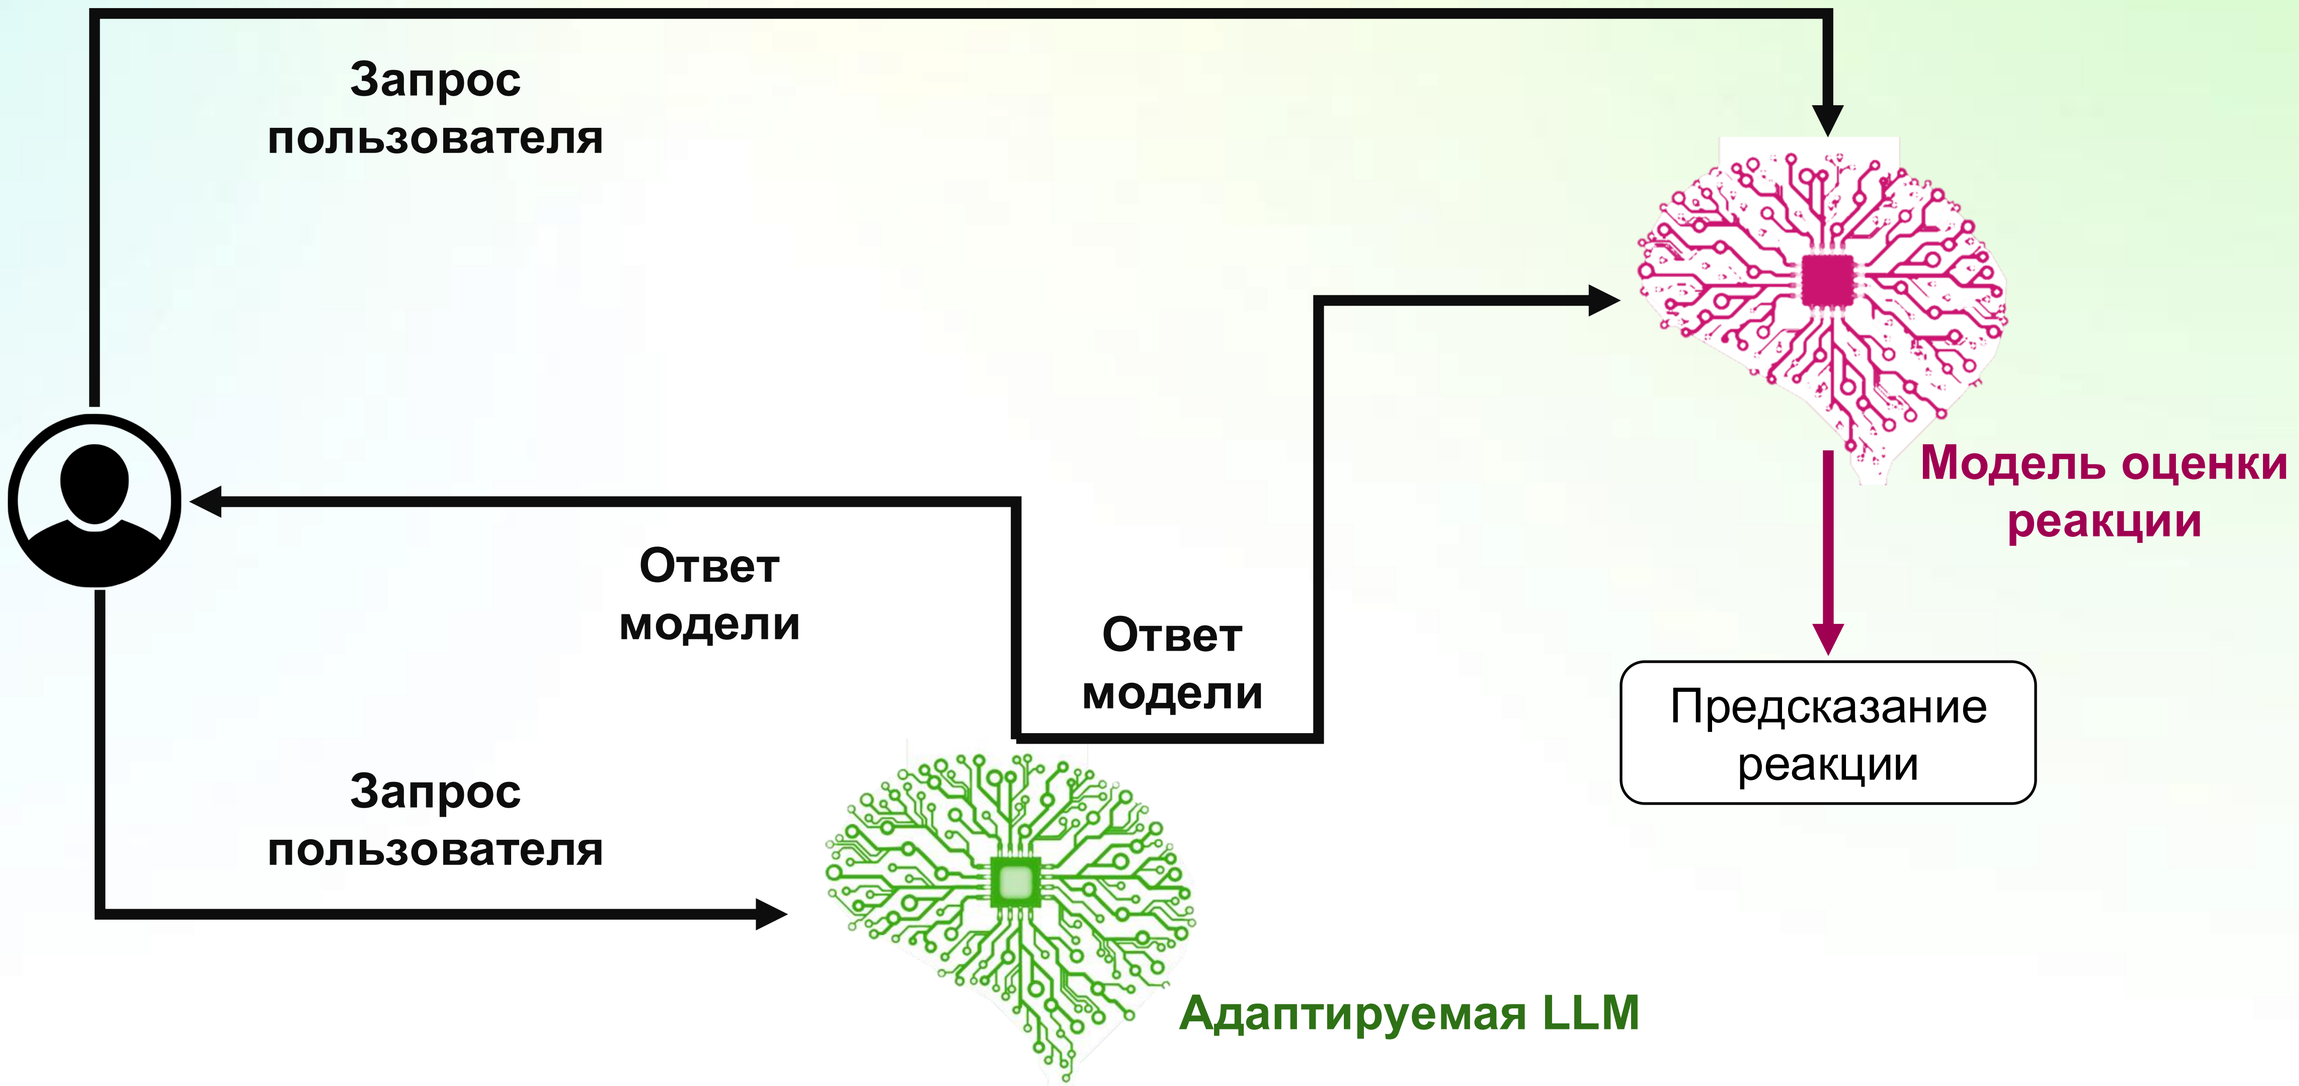

Большие Языковые модели/RLHF

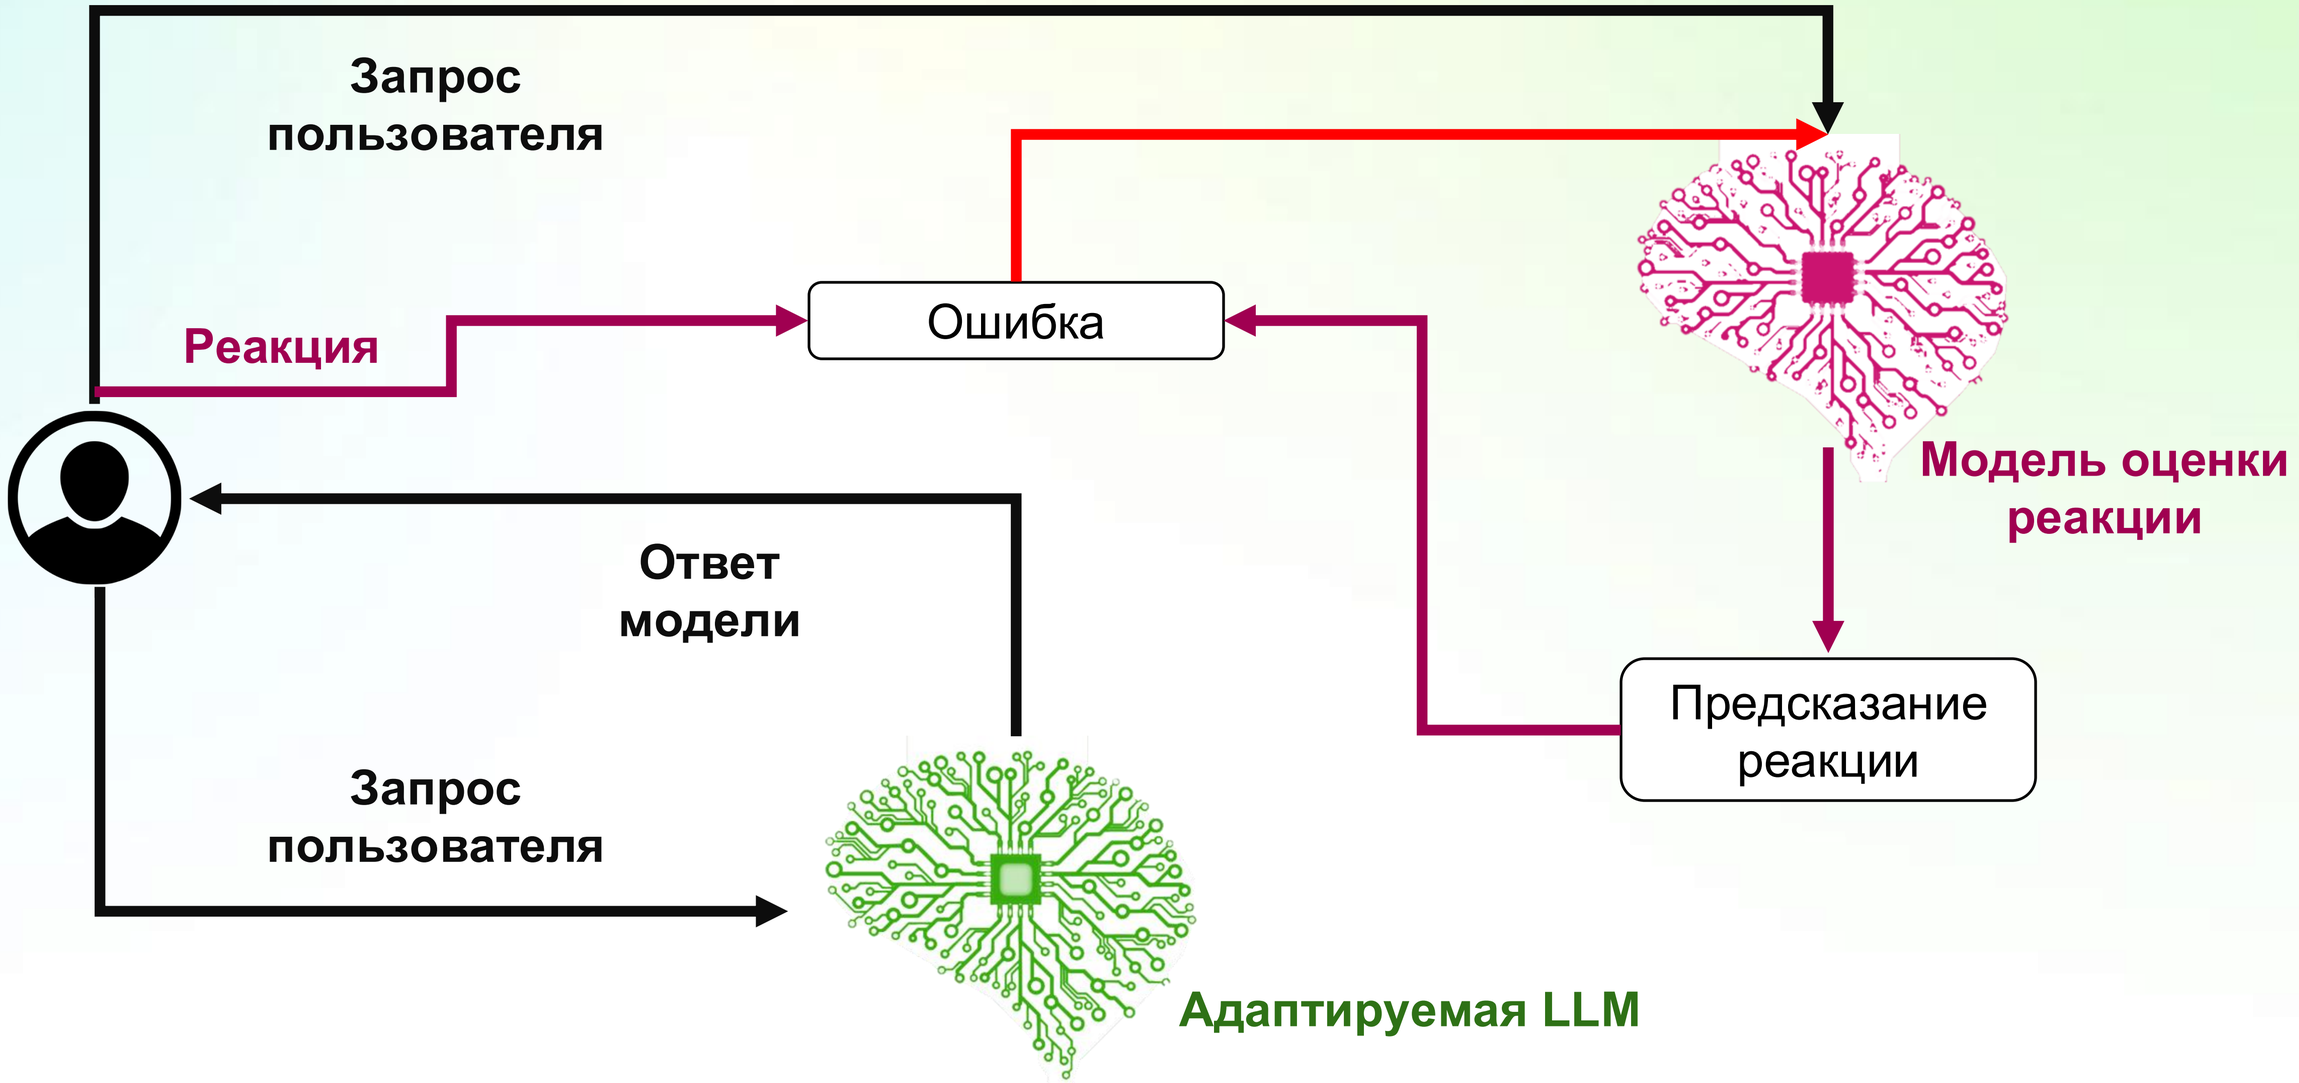

Большие Языковые модели/RLHF

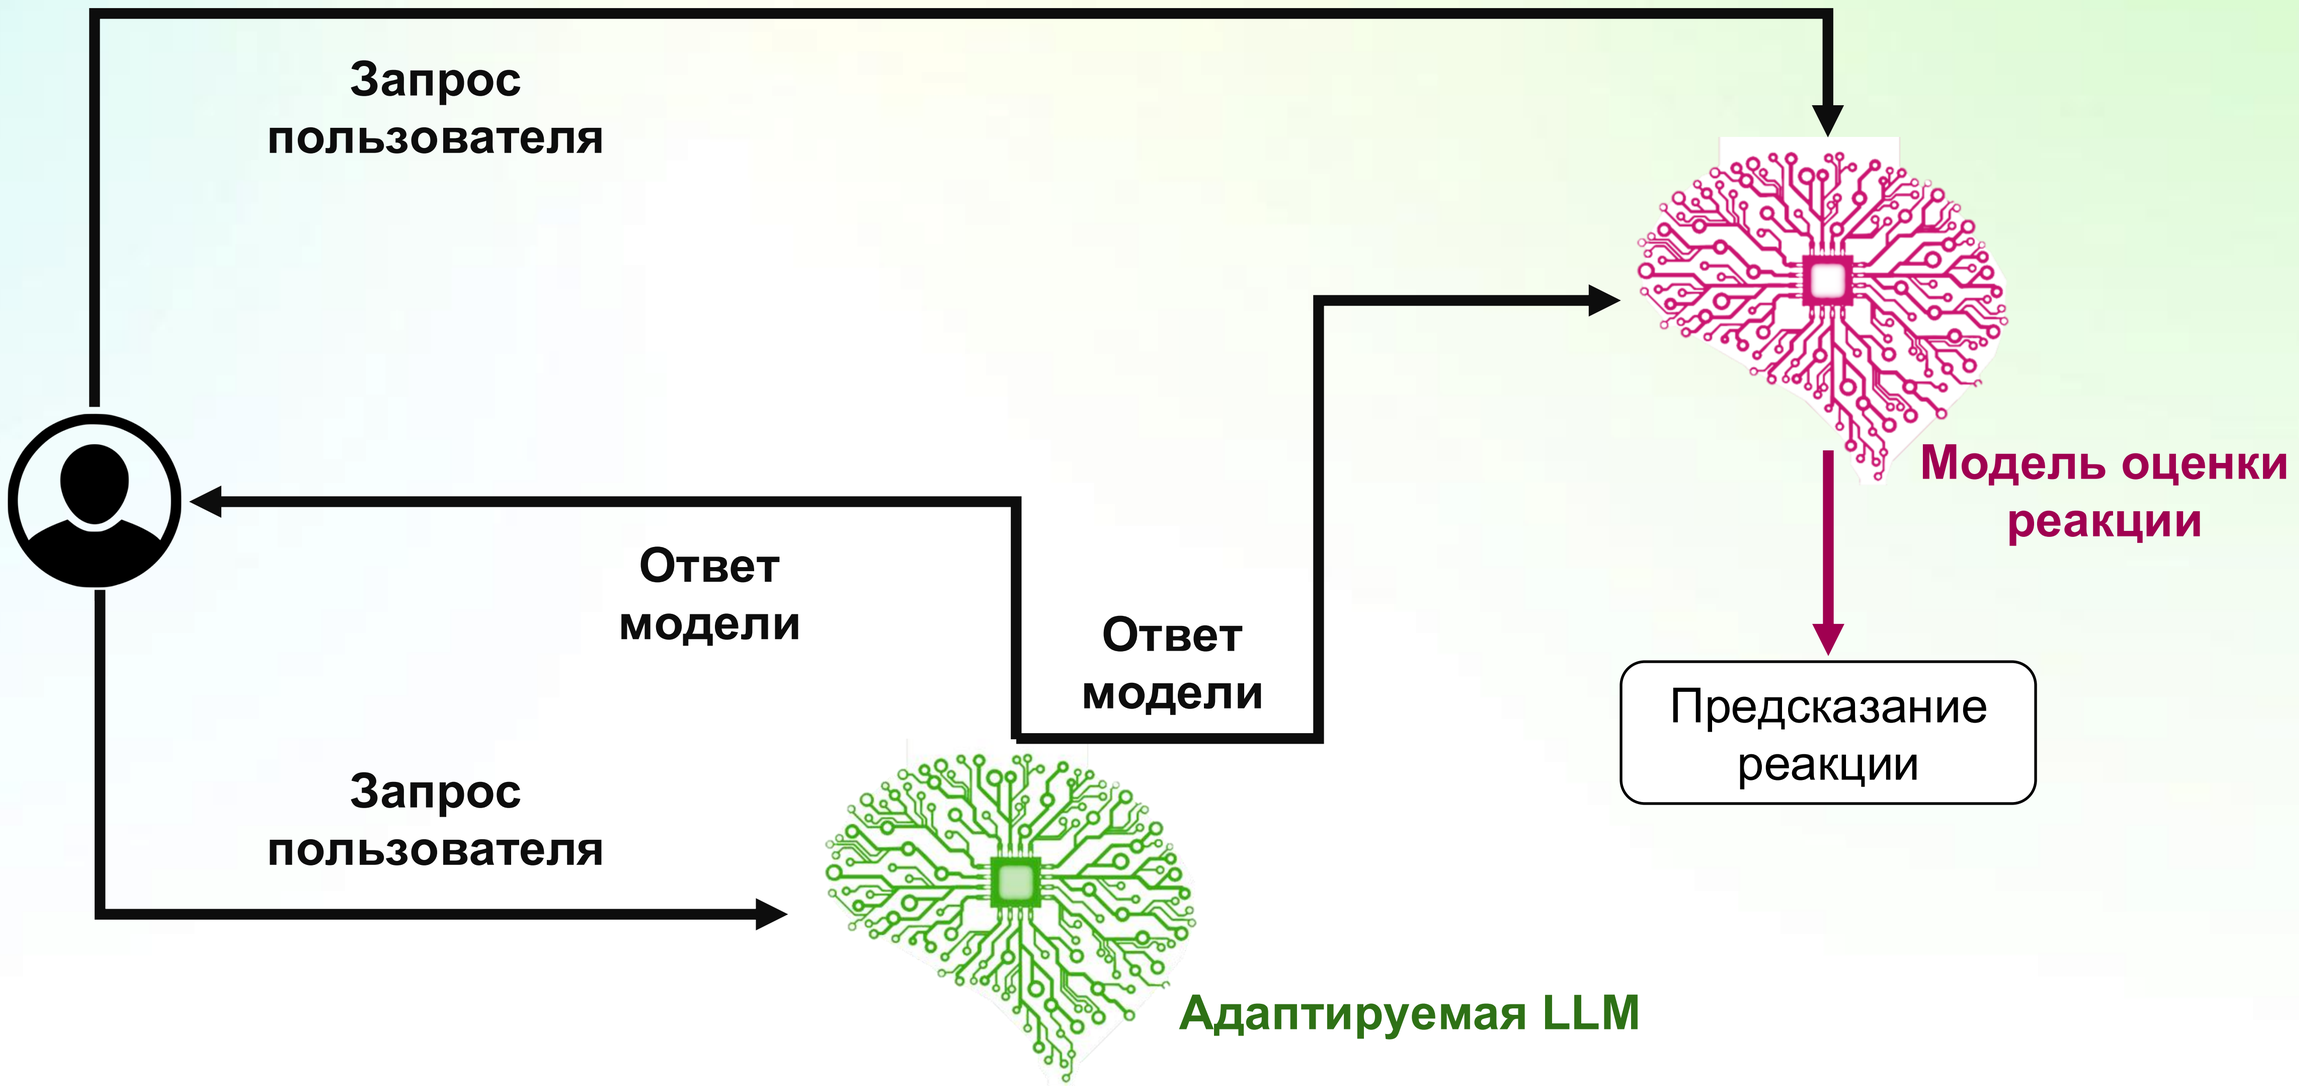

Большие Языковые модели/RLHF

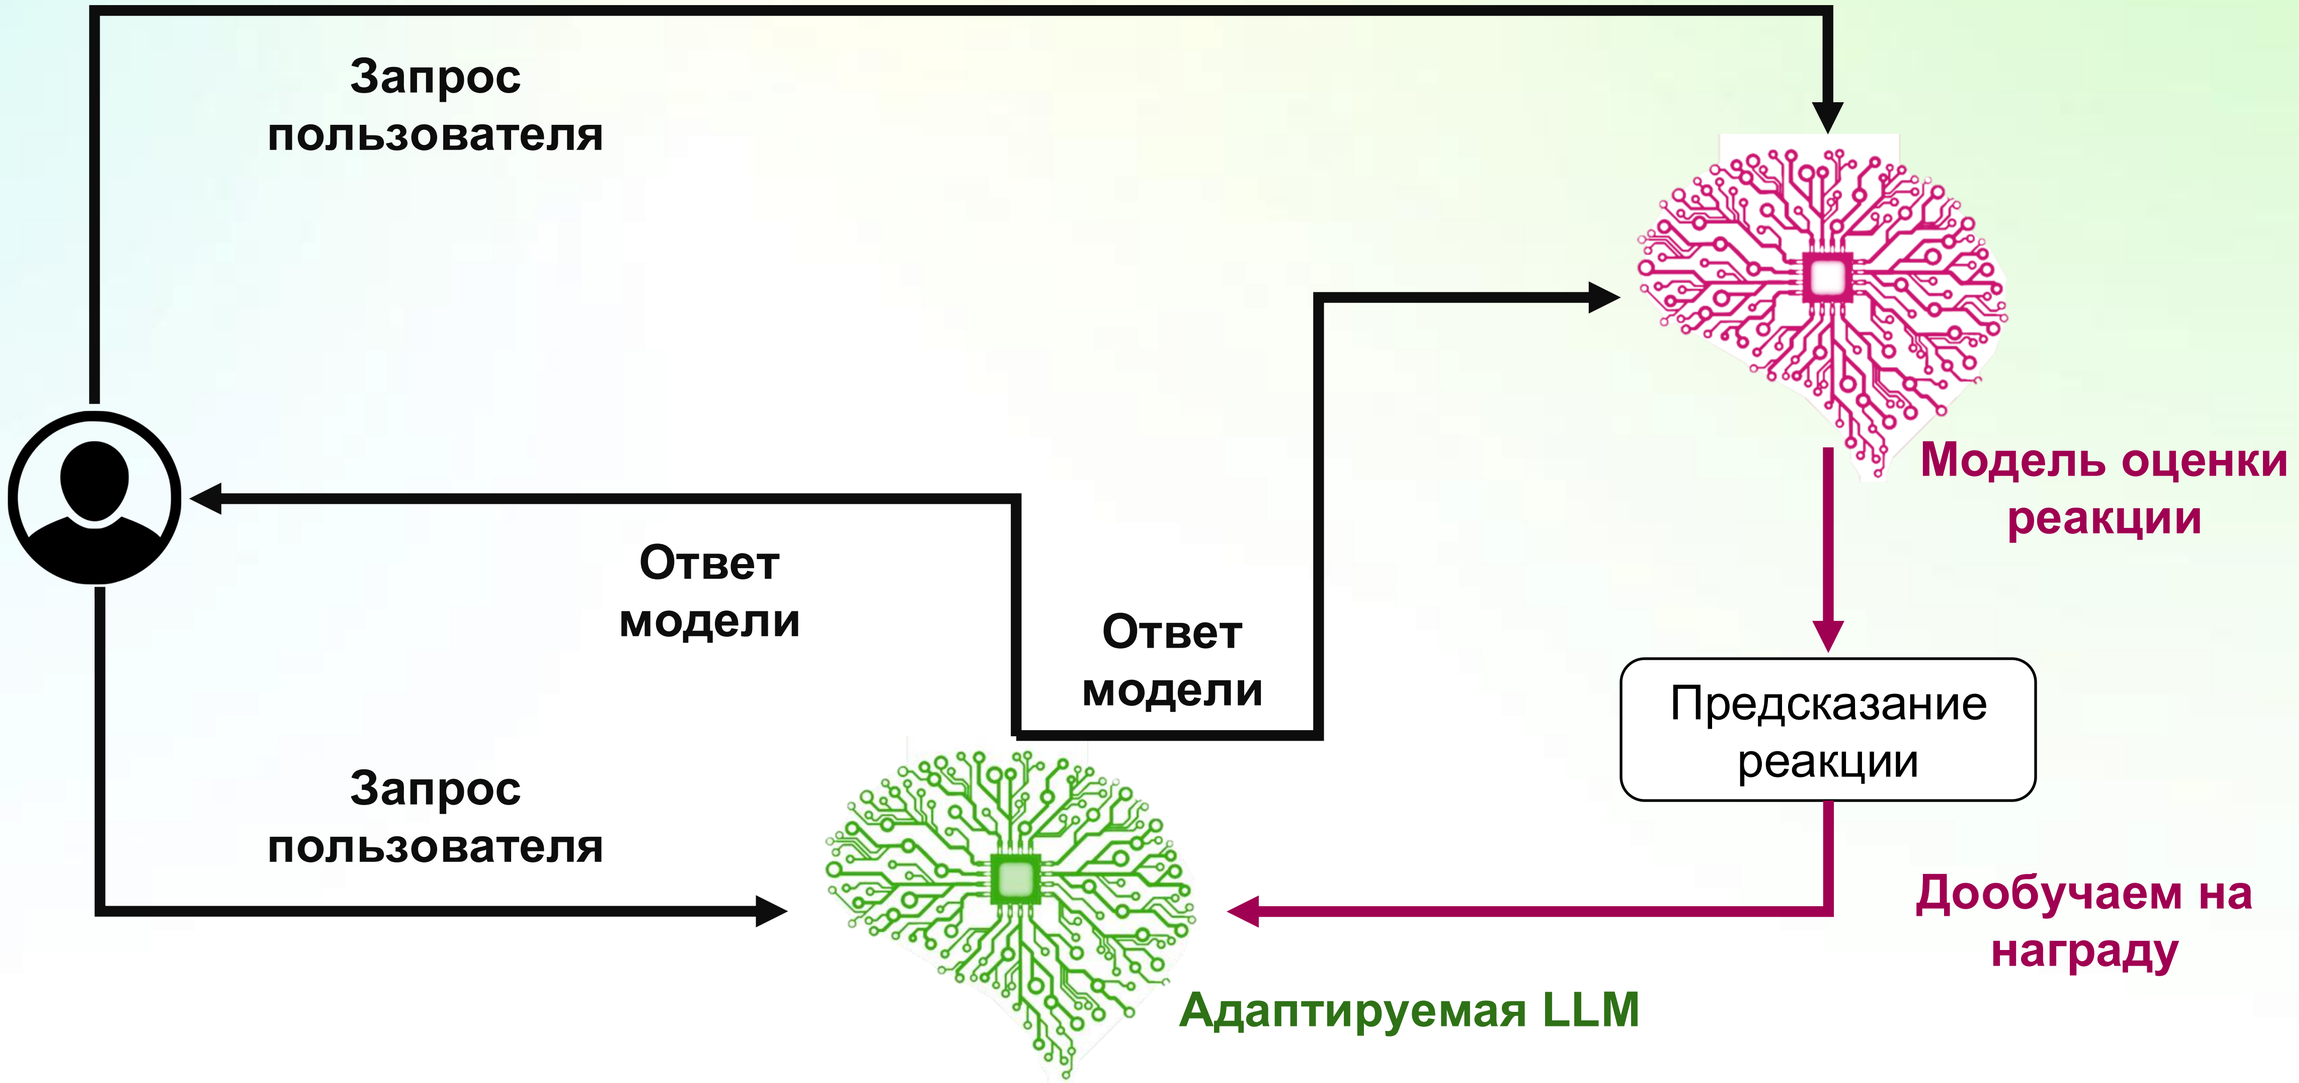

Большие Языковые модели/адаптация

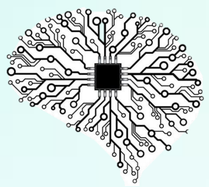

Собственная LLM

1. Безопасность данных
2. Развитие отечественных технологий
3. Высокая стоимость разработки
4. Многочисленность задач

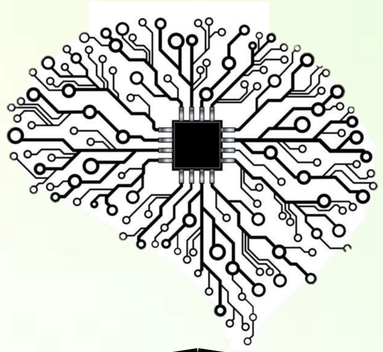

Внешняя LLM

Дообучение

1. Простой в запуске
2. Требует больших ресурсов и данных
3. Дорогостоящий процесс для одной задачи

RAG

1. Не требует дообучения
2. Много модификаций для улучшения
3. Высокий риск галлюцинаций

RLHF

1. Тонкая стилистическая настройка
2. Дорогая и спорная разметка

Контактная информация

email: aoborevskiy@hse.ru

телеграмм: @bor_loco

@BOR_LOCO

СБЕР УНИВЕРСИТЕТ

Спасибо за внимание!